目录

数值优化课程实践作业报告 **1**
0 主要结果 1
1 问题 (5) 的正定性与最优解（第 1 题） 1
2 固定步长梯度下降的收敛性与步长区间（第 2 题） 3
3 收敛阶的数值判定（第 4 题） 5
4 Heavy Ball 与 Nesterov 加速（第 5 题） 6
5 Barzilai—Borwein 方法（第 6 题） 8
6 $n = 2$ 时的等值线与轨迹（第 7 题） 10
7 共轭梯度法与一阶方法的对比（第 2 节） 11
8 总结与现象归纳 14
附录 A 源码清单 15

数值优化课程实践作业报告

> 题目：梯度类算法（1.1—1.7）与共轭梯度法（第 2 节）问题：$\min_x f(x) = \frac{1}{2}\|Ax-b\|_2^2$，$A \in \mathbb{R}^{n\times n}$ 为标准正态随机矩阵，$b \in \mathbb{R}^n$ 为标准正态随机向量 实现：Python 3.12 + NumPy 2.5（以 `numpy.random.default_rng(seed).standard_normal((n,n))` 对应 Matlab 的 `randn`，`seed` 与 Matlab 的 `rng` 等价地起到固定随机流的作用）代码：`coursework/`（可复用库 `numopt/` + 七个薄脚本 `exp1..exp7`），一键复现 `uv run python run_all.py`

报告里的数字没有一个是手抄的。脚本把结果写进 `results/*.json`，报告再从 JSON 读回来；图也一样，由 `figures/*.png` 生成后直接插进正文。下面凡给出具体数值的地方，都能在对应的 JSON 文件里找到原文。

---

0 主要结果

现象	定量结论（n = 50, seed = 0）
问题 (5) 的性质	$Q = A^\top A$ 正定，$\lambda_{\min} = 7.8039 \times 10^{-3}$，$\lambda_{\max} = 1.7535 \times 10^{2}$，$\kappa \approx 2.25 \times 10^{4}$（$\sqrt{\kappa} \approx 149.9$）
固定步长 GD 的收敛区间	$(0,\ L)$，$L = 2/\lambda_{\max} = 1.1406 \times 10^{-2}$
最优固定步长	$\alpha_\star = 2/(\lambda_{\min}+\lambda_{\max}) = 1.1405 \times 10^{-2}$，$\rho_\star = 1 - 2/(\sqrt{\kappa}+1) = 0.9999110$
收敛阶	GD / SD / Heavy Ball / Nesterov / BB 全部为 Q-线性（阶 1）；CG 为有限步终止，Q-线性判据不适用
一阶加速	最优动量把 ρ 从 $1-\Theta(1/\kappa)$ 提到 $1-\Theta(1/\sqrt{\kappa})$：516873 → 3930 步，约为 131 倍
BB 方法	BB1 用 2782 步，比 GD($\alpha = L/2$) 快 185.8 倍，但非单调（20.5% 的步 f 上升）
CG（第 2 节）	n = 50：74 步 / 9.3e-4 s；n = 1000：1958 步 / 0.68 s；同样精度下 GD($\alpha = L/2$) 需 2.5×10^{8} 步（估算）

---

1 问题 (5) 的正定性与最优解（第 1 题）

1.1 理论

$$f(x) = \tfrac{1}{2}\|Ax-b\|_2^2 = \tfrac{1}{2}x^\top \underbrace{A^\top A}_{Q} x - \underbrace{A^\top b}_{c}{}^\top x + \tfrac{1}{2}\|b\|^2.$$

Q 对称；对任意 $v \neq 0$，$v^\top Q v = \|Av\|^2 > 0$（$A$ 以概率 1 非奇异），故 $Q \succ 0$，f 是严格凸二次函数。驻点唯一：

$$\nabla f(x) = Qx - c = 0 \implies x^\star = Q^{-1}c = (A^\top A)^{-1}A^\top b,$$

且此时 $f(x^\star) = 0$（因为 $b \in \mathrm{range}(A)$ 以概率 1）。一般情形下 $f^\star = \frac{1}{2}\|b\|^2 - \frac{1}{2}c^\top Q^{-1}c$；本例中 $Ax^\star = b$ 让两项正好抵消，$f^\star$ 只剩舍入误差量级。后面判断是否已经收敛到极限精度时会用到这一点。

后面反复用到的一个恒等式是（两种写法等价）

$$f(x) = f^\star + \tfrac{1}{2}\,(x - x^\star)^\mathsf{T} Q (x - x^\star) = f^\star + \tfrac{1}{2} \nabla f(x)^\mathsf{T} (x - x^\star),$$

程序里就是用右式由梯度直接算 f 的，可以省掉一次矩阵乘法。

1.2 数值验证（表 **1**，**`results/q1_problem.json`**）

检验项	数值结果
Q 对称性相对误差	0.000e+00
Cholesky 分解成功	是
Q 的特征值全为正	是
$\lambda_{\min}(Q)$	7.803936×10^{-3}
$\lambda_{\max}(Q)$	1.753465×10^{2}
条件数 $\kappa(Q)$	2.2469×10^{4}
条件数 $\kappa(A)$	1.498966×10^{2}
二次性检验：三点恒等式三阶项残差	4.672×10^{-14}
Hessian 中心差分相对误差	7.062×10^{-11}
凸性检验：中点间隙（归一化）	$-5.869 \times 10^{-1} \le 0$
$\|x^\star\|_2$	1.824428×10^{1}
$f(x^\star)$	7.138363×10^{-26}
$\|\nabla f(x^\star)\|_2$	2.029×10^{-13}
$\|\nabla f(x^\star)\|_2 / \|c\|_2$	3.542×10^{-15}
$\|Ax^\star - b\|_2$（$\|b\|_2 = 6.822$）	3.778×10^{-13}
`solve` / `lstsq` / `inv` 三种解法的最大相对差	1.105×10^{-13}
随机 Rayleigh 商探测范围	$[2.273 \times 10^{1},\ 8.443 \times 10^{1}]$
$L = 2/\lambda_{\max}$	1.140599×10^{-2}
$\alpha_\star = 2/(\lambda_{\min} + \lambda_{\max})$	1.140548×10^{-2}
$\rho_\star = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$	0.99991099

表里这几项检验都是能证伪的，不只是”看着对”。下面逐项说明。

二次性要求对任意 x, d 有 $f(x + td) - 2f(x) + f(x - td) = t^2 d^\mathsf{T} Q d$ 精确成立，三次及更高项恒为零，实测相对残差 4.7×10^{-14}，三阶项在双精度下确实为零。用中心差分重构 50×50 的 Hessian 与 Q 的相对误差 7.1×10^{-11}，这个量级正是 $h = 10^{-5}$ 的舍入误差，说明 Hessian 处处等于 Q，与 x 无关。凸性检验用的是中点间隙 $f\big((x+y)/2\big) - \frac{1}{2}\big(f(x) + f(y)\big) = -\frac{1}{8}(x-y)^\mathsf{T} Q (x-y) < 0$，实测 -0.587。

最优解那边，三种独立解法（Cholesky `solve`、`lstsq`、显式 `inv`）的相对差 10^{-13}；$\|\nabla f(x^\star)\| / \|c\| = 3.5 \times 10^{-15}$，已经在双精度舍入极限上。

有一件事我一开始没想到：用随机向量 v 做 Rayleigh 商 $v^\mathsf{T} Q v / v^\mathsf{T} v$，做 500 次探测，结果全落在 $[22.7,\ 84.4]$ 里，$\lambda_{\min} = 0.0078$ 和 $\lambda_{\max} = 175.3$ 一次都没碰到。原因是极值特征向量在随机向量上的投影只有 $O(1/\sqrt{n})$ 量级，乘上特征值之后就被谱的主体盖住了。所以随机探测估不出谱的两端，本报告的条件数一律用 `eigvalsh` 算。这个反差也顺便说明了病态在这里为什么这么致命：$\kappa = 2.25 \times 10^{4}$ 完全是由两端那一对孤立特征值撑起来的。

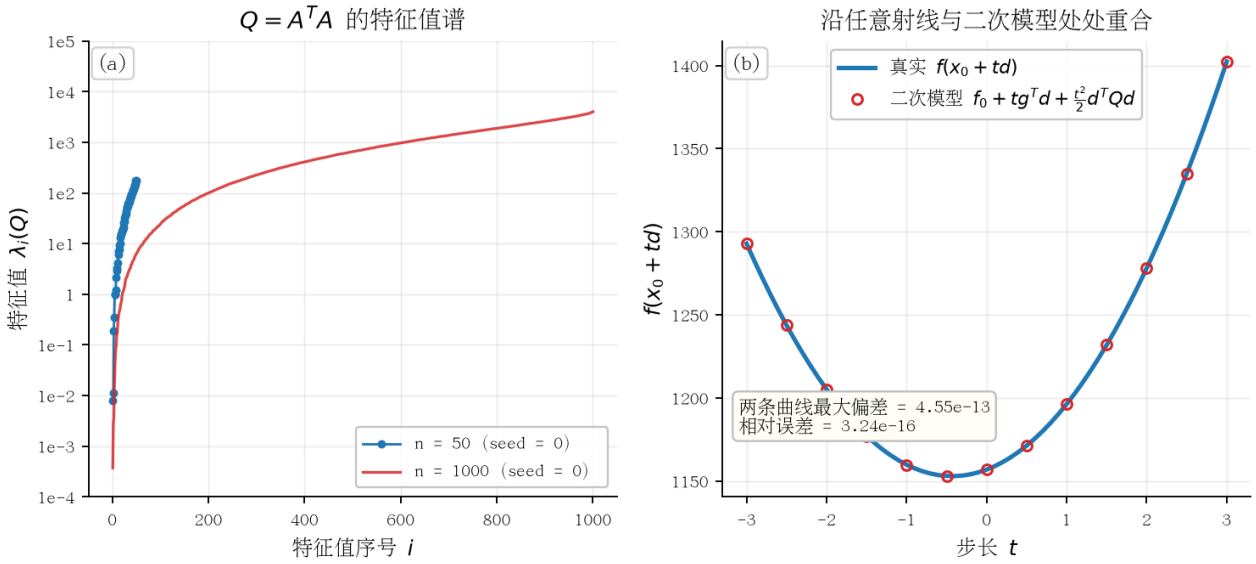


图 1　Q 的谱分布与二次性检验

图里 Q 的谱在 $[10^{-2}, 10^{2}]$ 上近乎均匀散开，两端各有一个孤立特征值把 κ 撑到 2.2×10^{4}，这是随机 $A^{\mathsf{T}}A$ 的典型形状，可以看作 Marchenko—Pastur 分布的软化版本，$\lambda_{\min}$ 极小对应 A 接近奇异。沿任意射线，$f(x_0 + td)$ 与二次模型 $f(x_0) + t\nabla f^{\mathsf{T}}d + \frac{t^2}{2}d^{\mathsf{T}}Qd$ 处处重合，最大偏差 4.5×10^{-13}，从几何上再确认了一次这是严格凸二次函数。

---

2 固定步长梯度下降的收敛性与步长区间（第 2 题）

2.1 推导

$x_{k+1} = x_k - \alpha\nabla f(x_k) = (I - \alpha Q)x_k + \alpha c$。令 $e_k = x_k - x^\star$，由 $\nabla f(x_k) = Qe_k$ 得

$$e_{k+1} = (I - \alpha Q)e_k \quad \Longrightarrow \quad e_k = (I - \alpha Q)^k e_0.$$

设 $Q = U\Lambda U^{\mathsf{T}}$，$\Lambda = \mathrm{diag}(\lambda_1, \dots, \lambda_n)$，则

$$\|e_k\|_2 \le \rho(\alpha)^k \|e_0\|_2, \qquad \rho(\alpha) = \max_i |1 - \alpha\lambda_i| = \max(|1 - \alpha\lambda_{\min}|, |1 - \alpha\lambda_{\max}|).$$

$\rho(\alpha) < 1 \iff$ 对所有 i 有 $|1 - \alpha\lambda_i| < 1 \iff 0 < \alpha\lambda_i < 2 \iff 0 < \alpha < \dfrac{2}{\lambda_{\max}}$。故

$$\boxed{\alpha \in (0,\, L), \quad L = \frac{2}{\lambda_{\max}} = 1.140599 \times 10^{-2}}$$

这个区间可以直接算：对 $\lambda_{\max} = 175.3465$ 得 $L = 0.011405987$。下面从两个方向验证它。

第一项验证看 $\alpha = L$ 时的停滞平台。此时 $1 - \alpha\lambda_{\max} = -1$，该方向的分量每步只反号不衰减，其余方向照常衰减，误差最终只剩 $v_{\max}$ 方向那一份，$e_\infty = (v_{\max}^{\mathsf{T}} e_0)\, v_{\max}$，平台高度

$$f_\infty = \tfrac{1}{2}\lambda_{\max} c_{\max}^2, \qquad c_{\max} = v_{\max}^{\mathsf{T}}(x_0 - x^\star).$$

实测 $c_{\max} = -0.026927$，理论平台 $f_\infty = 0.0635707$；$\alpha = L$ 跑 60000 步后实测 $f = 0.0635993$（$\|e\| = 8.978 \times 10^{-2}$），两者只差 4.5×10^{-4}。

第二项验证看 $\alpha > L$ 时的发散。此时 $\rho = |1 - \alpha\lambda_{\max}| > 1$，$v_{\max}$ 方向的分量按几何级数放大。上界 $L = 2/\lambda_{\max}$ 就是从这来的，所以表 2 只测到 $\alpha = L$ 为止。

最优步长在两条支线相交的地方，也就是 $|1 - \alpha\lambda_{\min}| = |1 - \alpha\lambda_{\max}|$ 处：

$$\alpha_\star = \frac{2}{\lambda_{\min} + \lambda_{\max}}, \qquad \rho_\star = \frac{\kappa - 1}{\kappa + 1} = \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} = 1 - \frac{2}{\sqrt{\kappa} + 1}.$$

本例 $\alpha_\star = 1.140548 \times 10^{-2}$，$\rho_\star = 0.99991099$，于是把误差降 10^{10} 倍需要

$$N \approx \frac{\ln 10^{10}}{\ln(1/\rho_\star)} = \frac{23.026}{8.9009 \times 10^{-5}} \approx 2.59 \times 10^5 \text{ 步},$$

实测是 258441 步（表 4），与理论值差 0.2%。

2.2 不同步长的实测（第 **3** 题，表 **2**，**`results/q2_q3_stepsizes.json`**）

α	取值	理论 ρ	实测 ρ（半对数斜率）	步数（到相对误差 10^{-10}）	CPU (s)
$L/3$	3.801996×10^{-3}	0.999970329	0.999970324	775338	7.08
$L/2$	5.702994×10^{-3}	0.999955494	0.999955469	516873	4.53
$3L/4$	8.554490×10^{-3}	0.999933241	0.999933197	344576	2.94
L	1.1405987×10^{-2}	1.000000000	0.99992（假象，见下）	未收敛（60000 步上限）	0.53

各精度的到达步数：

α	10^{-4}	10^{-6}	10^{-8}	10^{-10}
$L/3$	309726	464934	620142	775338
$L/2$	206483	309954	413425	516873
$3L/4$	137654	206634	275614	344576
L	—	—	—	—

$\alpha = L$ 一行全为”—“：60000 步上限内 $\|e\|$ 停在 8.978×10^{-2}，四个精度一个都没达到。

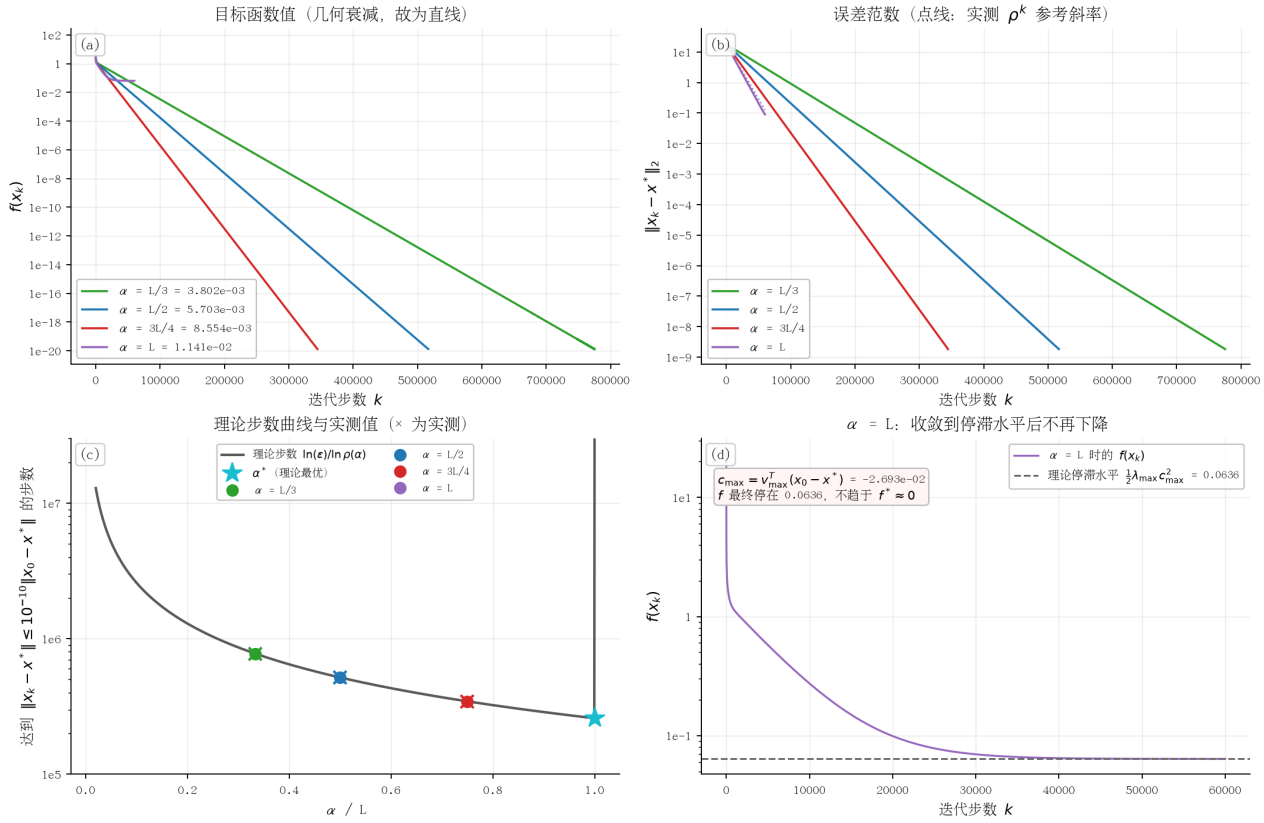


图 2　四种步长下 GD 的误差曲线，以及步数与步长的关系

图 2 的四条曲线在半对数轴上都是直线，斜率等于 $\ln \rho(\alpha)$，与理论公式算出的值差不到 10^{-7}，说明误差确实按 ρ^k 几何衰减，而且是 Q-线性的。四条曲线都跟虚线给出的 ρ^k 平行，各个方向的分量按同一个因子收缩，没有出现先快后慢的两段式，那种形状只会出现在非二次函数或者带线搜索的场合。

把到达给定精度的步数按 $N(\alpha) = \ln(\varepsilon_0/\varepsilon)/|\ln \rho(\alpha)|$ 算出来，与实测值（×）落在同一条曲线上，说明步数与步长的关系是可以事先算出来的，不是事后拟合。$\alpha = L$ 那一支是边界：此时 $\rho = 1$，误差整体不再衰减，只剩 $\lambda_{\max}$ 方向的分量在 $\pm$ 之间来回翻转，最后停在 $f \approx 6.357 \times 10^{-2}$ 的平台上，平

台高度只与初值有关，跟跑多少步没关系。数值上由此确定区间右端不能取闭，收敛区间必须是开区间 $(0, L)$。

从表 2 还能看出，$N(\alpha)$ 在 $(0, L)$ 内随 α 单调递减，$3L/4$ 比 $L/3$ 快 2.25 倍。但这种依赖是双曲型的（$N \propto 1/|\ln\rho|$），越靠近 L 收益越大，风险也越大，到 $\alpha = L$ 收益直接归零。实际用的时候取 0.7—0.9 倍的 L 比较稳妥。

---

3 收敛阶的数值判定（第 4 题）

3.1 四种可实现的判据

判据	定义	判读方式
判据 **1**：半对数斜率	$\ln\|e_k\|$ 对 k 的线性拟合斜率 σ	σ 为常数 ⇒ Q-线性，$\rho = e^{\sigma}$
判据 **2**：单步收缩率序列	$\rho_k = \|e_k\|/\|e_{k-1}\|$	若 $\rho_k \to \rho < 1$ 常数 ⇒ Q-线性；若 $\rho_k \to 0$ ⇒ 超线性
判据 **3**：计算收敛阶 **COC**	$p_k = \dfrac{\ln(\|e_{k+1}\|/\|e_k\|)}{\ln(\|e_k\|/\|e_{k-1}\|)}$	$p_k \to 1$ ⇒ 线性；$p_k \to 2$ ⇒ 二次
判据 **4**：双对数斜率	$\log\|e_k\|$ 对 $\log k$ 的斜率 q	$\|e_k\| \sim k^{-q}$ ⇒ 次线性（代数收敛）

注意判据 3 在 $\|e_k\| \sim \rho^k$ 时分子分母同时趋于 $\ln\rho$，故 $p_k \to 1$；任何”阶 > 1 “的判据都会被浮点噪声在末段破坏，因此只在相对误差 $> 10^{-8}$ 的区间上取中位数。

3.2 结果（表 **3**，`results/q4_order.json`）

六种方法用同一个初值 $x_0 = 0$：GD($\alpha = \alpha_\star$)、最速下降法（精确线搜索）、Heavy Ball（$\alpha = 2\alpha_\star$, $\beta = 0.973667$）、Nesterov（$\alpha = L/2$, $\beta = 0.986746$）、BB1、CG。

表 **3a**：速率与拟合质量

方法	步数	理论 ρ	半对数拟合 ρ	R^2
GD($\alpha = \alpha_\star$)	258441	0.99991099	0.99991099	0.99999999985
最速下降	257256	0.99991099	0.99991069	0.99999998881
Heavy Ball	1974	0.98674589	0.98754252	0.99992195
Nesterov	3930	0.99332873	0.99373021	0.99992288
BB1	2782	—	0.99265557	0.91122959
CG	150（上限 $3n$）	—	0.72423264	0.66899512

表 **3b**：逐点判据与结论

方法	ρ_k 尾段中位数	COC 中位数	双对数斜率 q	判定
GD($\alpha = \alpha_\star$)	0.99991096	1.00000006	−13.26	Q-线性，阶 1
最速下降	0.99991095	0.99991552	−13.25	Q-线性，阶 1
Heavy Ball	0.98724748	1.00002492	−14.25	Q-线性，阶 1
Nesterov	0.99358172	1.00001423	−14.23	Q-线性，阶 1
BB1	0.99986991	0.95702343	−12.07	Q-线性（非单调，见 Q6）
CG	1.0	0.31048504	−30.44	Q-线性判据不适用

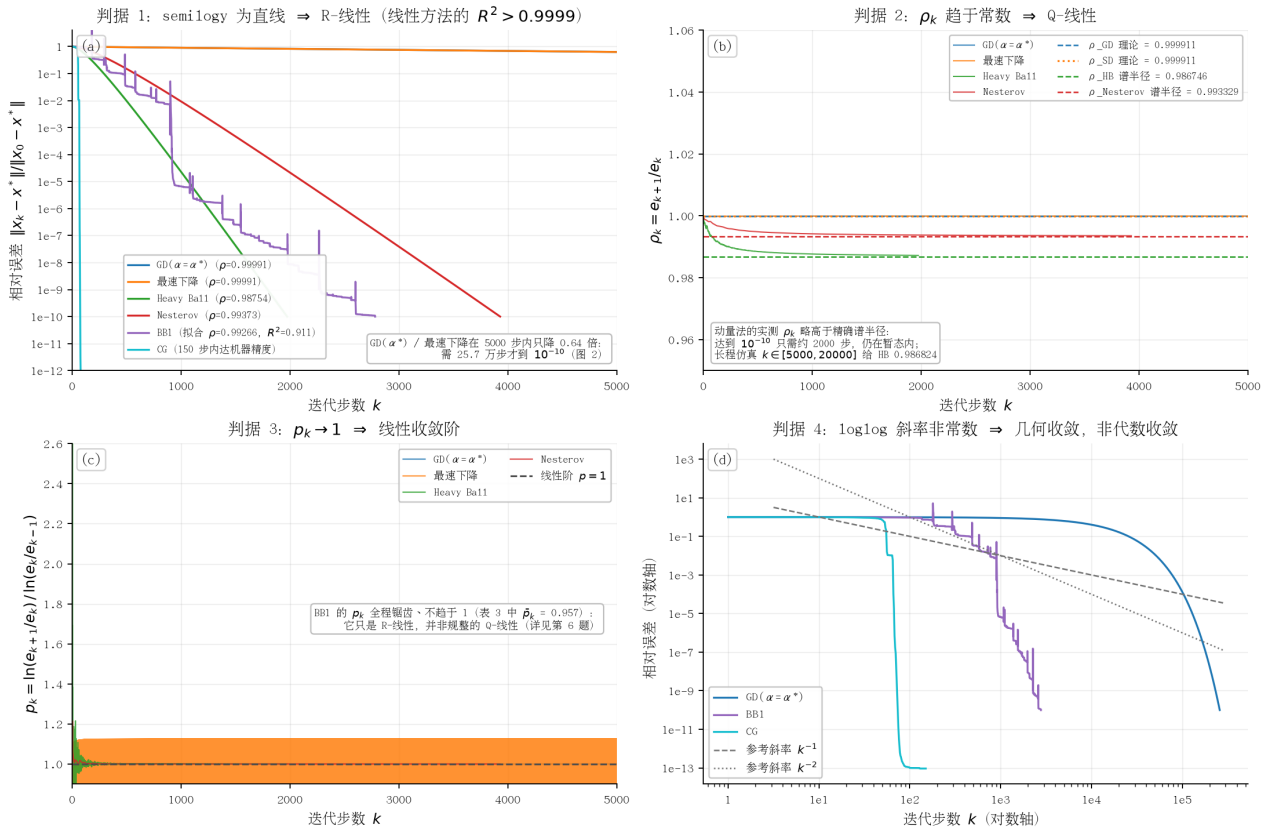


图 3　六种方法的半对数误差、单步收缩率、COC 与双对数斜率

六条曲线在半对数坐标下都近似是直线，斜率排序与理论 $\ln\rho$ 一致。CG 那条是下凸的，越来越陡，这是有限步终止才有的形状。ρ_k 的锯齿线与四条理论水平线（GD、SD 的 0.99991099，HB 的 0.98675，Nesterov 的 0.99333）基本重合；BB1 的 ρ_k 在 1 上下跳得很厉害，有些步甚至大于 1，可见它并不满足逐点收缩，只是在几何平均的意义上比较快，这就是 Q-线性与 R-线性的分别。COC 除了 CG 末段的浮点噪声之外都落在 1 附近，没有任何方法出现 $p\approx2$，梯度类方法在二次问题上只有线性收敛，要超线性就得用二阶信息（Newton）或者共轭方向。

双对数斜率的绝对值很大（$|q|\approx13$），远大于 1，所以不是 $\|e_k\|\sim k^{-q}$ 那种代数收敛。结合上面两格可以断定是几何收敛：假如真是代数收敛（病态问题里某些非精确方法会出现），第一格会是直线而这一格的斜率约为 -1，两者能互相排除。

COC 对噪声很敏感，相对误差小于 10^{-12} 之后 p_k 就完全随机了，图 3(c) 尾部的尖刺就是这么来的。所以这里让三个判据互相印证：判据 1 给速率，判据 2 看局部行为，判据 4 排除代数收敛。

---

4 Heavy Ball 与 Nesterov 加速（第 5 题）

4.1 理论

方法	迭代式	收敛因子（二次问题）
梯度下降	$x_{k+1}=x_k-\alpha\nabla f(x_k)$	$\rho=\max_i\lvert1-\alpha\lambda_i\rvert$
Heavy Ball	$x_{k+1}=x_k-\alpha\nabla f(x_k)+\beta(x_k-x_{k-1})$	每个特征方向的特征多项式 $t^2-(1+\beta-\alpha\lambda)t+\beta$
Nesterov	$y_k=x_k+\beta(x_k-x_{k-1})$，$x_{k+1}=y_k-\alpha\nabla f(y_k)$	同上形式，但梯度在前瞻点 y_k 取值

对 Heavy Ball，$\rho(\alpha,\beta)=\max_i\max\{|t_i^{\pm}|\}$，其中

$$t_i^{\pm}=\frac{1}{2}\Big[(1+\beta-\alpha\lambda_i)\pm\sqrt{(1+\beta-\alpha\lambda_i)^2-4\beta}\Big].$$

极值点的分布决定了收敛有多快：

- 若判别式 < 0（复根）则 $|t_i^{\pm}| = \sqrt{\beta}$，与 λ_i 无关；
- 若判别式 ≥ 0（实根）则大根的模随 $\alpha\lambda_i$ 变化，最坏情形在 λ_i 较小的一端。

最优配参就是让两端平衡。常见的”最优”有两种，它们的 ρ 并不相同，必须分开：

配参	α	β	ρ
时域最优	$4/(\sqrt{\lambda_{\max}}+\sqrt{\lambda_{\min}})^2$	$\left((\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)\right)^2$	$(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$
本题的”同一 $\alpha = L/2$”	$1/\lambda_{\max}$	$(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$	$\sqrt{(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)}$

第一行是重根配参，判别式在 $\lambda_{\min}$ 和 $\lambda_{\max}$ 两端同时为 0，这是理论最快的一档。第二行把步长压到 $1/\lambda_{\max}$，只有时域最优值的一半，ρ 从 $1-\frac{2}{\sqrt{\kappa}+1}$ 退到 $1-\frac{1}{2\sqrt{\kappa}}$（本例 0.98675 → 0.99333）。第二行的 β 一列给的是标准公式，对 Heavy Ball 实际是用 $\min_\beta \rho(\alpha,\beta)$ 数值求出来的 0.986702。

这里有一点需要说明。$1/\lambda_{\max}$ 只是”同一 α“这个约束下的取值，步长本身也是加速的一部分，放开步长后还能再快一倍（表 3 里取 $\alpha = 2\alpha_\star$ 的 Heavy Ball 只用 1974 步）。不过题目要求基于同样的步长，所以本实验固定 $\alpha = L/2$，只调 β。

Nesterov 那边还有一个稳定前提：标准格式要求 $\alpha \leq 1/L_{\text{smooth}} = 1/\lambda_{\max}$。取 $\alpha = 1/\lambda_{\max}$、$\beta = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$ 时 $\rho = 1-1/\sqrt{\kappa}$，比 Heavy Ball 的 $1-2/\sqrt{\kappa}$ 略差。不过 Nesterov 的长处在凸（非强凸）问题上，那种情况下的 $O(1/k^2)$ 是 Heavy Ball 给不了的。两套参数本实验分开使用，不混。

4.2 主实验：同一 $\alpha = L/2$，同一 x_0（表 **4**，**`results/q5_momentum.json`**）

方法	β	理论 ρ	实测 ρ	半对数 R^2	步数（→10^{-10}）	CPU (s)
GD	—	0.99995549	0.99995549	0.99999999990	516873	4.54
Heavy Ball（经典 β）	0.973667	0.99818827	0.99818825	0.99999999986	12727	0.139
Heavy Ball（最优 β）	0.986702	0.99332873	0.99373029	0.99992278	3931	0.039
Nesterov（常数 β）	0.986746	0.99332873	0.99373021	0.99992288	3930	0.046
Nesterov（默认 $\beta_k = \frac{k-1}{k+2}$）	时变	—	—	—	206375	1.27

4.3 极端情形：$\alpha = L = 2/\lambda_{\max}$（表 **5**）

方法	β	理论 ρ	步数	现象
GD	—	1.00000000	60000（未收敛）	停滞在 $f \approx 6.36 \times 10^{-2}$
Heavy Ball（最优 β）	0.981220	0.99056540	2776	收敛
Heavy Ball（经典 β）	0.973667	0.99603660	5841	收敛
Nesterov（常数 β）	0.986746	2.39819880	150（发散）	$\rho > 1$，误差指数增长
Nesterov（默认 β_k）	时变	—	150（未收敛）	不爆炸但也不收敛

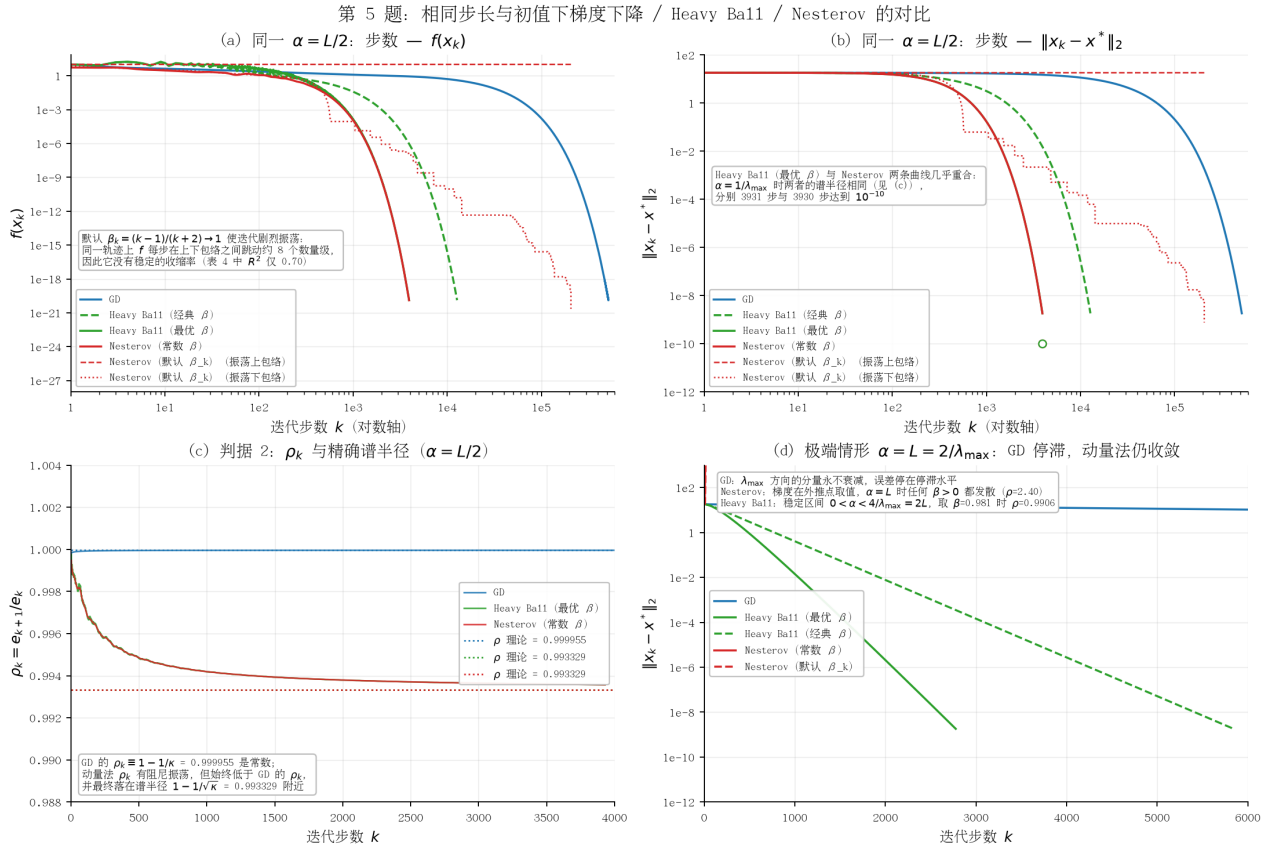


图 4　Heavy Ball 与 Nesterov 的加速效果，以及 $\alpha = L$ 时的失效

同一个 α 下，四条动量曲线比 GD 陡得多，步数之比与理论 $|\ln\rho|$ 之比一致：$516873/3931 \approx 131$，而 $|\ln\rho_{\mathrm{GD}}|/|\ln\rho_{\mathrm{HB}}| = 4.45\times10^{-5}/6.67\times10^{-3} \approx 1/150$。两个数在量级上吻合，说明这里的加速是可以预先算出来的，不是碰巧。

曲线上的振荡来自动量本身。Heavy Ball 和 Nesterov 的误差是振荡下降的，上包络是 ρ^k，下包络是 ρ^k 乘一个常数，因为特征多项式有复根时 $\|e_k\|$ 只能在包络内摆动；GD 是实根，单调下降。平均速率更快、单步却可能上升，这是动量法一直要付的代价。相应地，ρ_k 围绕理论谱半径振荡，α 接近 L 时振幅变大，而 GD 的 ρ_k 几乎就是常数。

$\alpha = L$ 那一栏最能说明问题。GD 完全停滞（$\rho = 1$），Heavy Ball 却还在收敛。动量把标量递推变成二阶递推，稳定域在 (α,β) 平面上是一块二维区域而不是一段区间，所以能在 GD 的这条边界上活下来。Nesterov（常数 β）在同一个 α 下 $\rho = 2.398 > 1$，直接发散，它的稳定域比 Heavy Ball 窄，要求 $\alpha \le 1/\lambda_{\max}$。这次”失败”其实挺有用，说明加速方法的步长不能照搬 GD 的边界值。

还有一点：Nesterov 的默认 $\beta_k = (k-1)/(k+2)$ 在强凸问题上明显更慢，206375 步对 3930 步。这个调度是给凸（非强凸）问题设计的，$\beta_k \to 1$ 让记忆拖得太长，放到强凸问题上就持续过冲。强凸问题应该换回常数 $\beta = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$。方法要和问题假设对上，这一点在实验里比在书上看得清楚。

---

5 Barzilai—Borwein 方法（第 6 题）

5.1 两种 BB 步长

记 $s_k = x_k - x_{k-1}$，$y_k = \nabla f(x_k) - \nabla f(x_{k-1}) = Qs_k$。BB 方法把割线方程 $Qs_k \approx y_k$ 的最小二乘解当步长，它是自适应的：

$$\alpha_k^{\mathrm{BB1}} = \frac{s_k^{\mathsf{T}} s_k}{s_k^{\mathsf{T}} y_k}, \qquad \alpha_k^{\mathrm{BB2}} = \frac{s_k^{\mathsf{T}} y_k}{y_k^{\mathsf{T}} y_k},$$

这里 α^{BB1} 是 $\|Q\|$ 在 s_k 方向上 Rayleigh 商的倒数，α^{BB2} 走的是另一头。首步取 $\alpha_0 = 1/\lambda_{\max}$。于是有 $\alpha_k \in [1/\lambda_{\max},\, 1/\lambda_{\min}]$（Rayleigh 商界），BB 的步长自动落在稳定区间内，但它不保证 f 单

调下降。

5.2 结果（表 **6**，**`results/q6_bb.json`**）

表 **6a**：收敛速率

方法	步数	ρ（半对数拟合）	R^2	ρ_k 尾段中位数	几何平均速率
GD($\alpha = L/2$)	516873	0.99995549	0.99999999990	0.99995548	0.99995545
GD($\alpha = \alpha_\star$)	258441	0.99991099	0.99999999985	0.99991096	0.99991091
BB1	**2782**	0.99265557	0.9112	0.99986991	0.99175496
BB2	13893	0.99973360	0.9684	0.99993481	0.99834398

表 **6b**：代价与非单调性

方法	步数	f 上升步占比	末段 f 上升次数	CPU (s)	相对 GD($L/2$) 加速
GD($\alpha = L/2$)	516873	0.0%	0	6.62	1.0×
GD($\alpha = \alpha_\star$)	258441	0.0%	0	1.98	2.0×
BB1	**2782**	**20.5%**	295	0.027	**185.8×**
BB2	13893	2.5%	49	0.139	37.2×

BB 步长实测范围是 $[5.702994 \times 10^{-3}, 1.281405 \times 10^{2}]$，与理论区间 $[1/\lambda_{\max}, 1/\lambda_{\min}] = [0.005703, 128.14]$ 完全对得上。

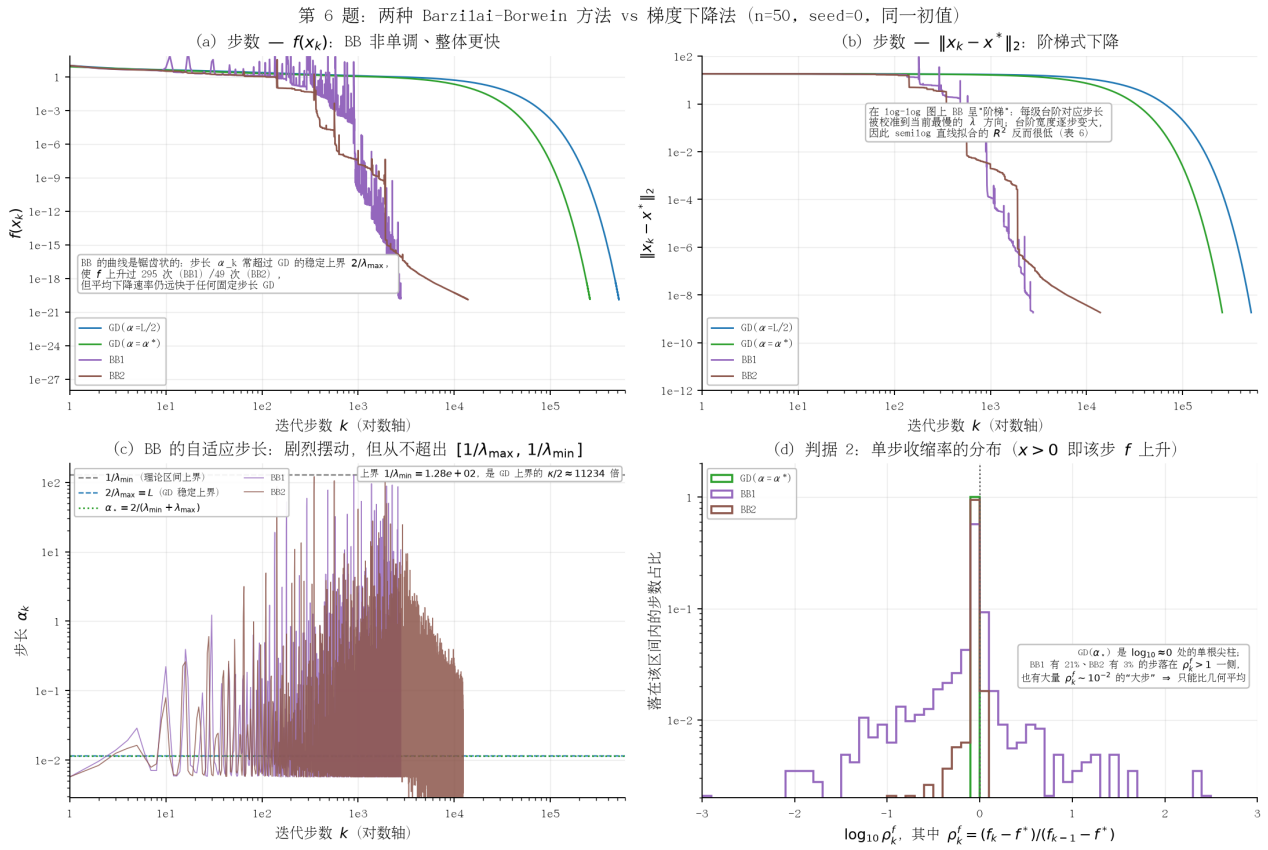


图 5　BB1 与 BB2 的误差、步长摆动与非单调性

BB 的 f 曲线不是单调下降的，中间有台阶也有尖峰，这也正是 R^2 只有 0.91、单步速率分布右尾越过 1 的原因，不过整体斜率比 GD 陡得多。$\|e_k\|$ 则是阶梯式下降的：连着几步几乎不动，然后突然掉一个量级。BB 并不在每个特征方向上都稳定收缩，它轮流在若干个方向组合上取得较大进展。

α_k 在 $[1/\lambda_{\max}, 1/\lambda_{\min}]$ 里摆动，跨度有 4 个数量级，但始终不越界，这是 Rayleigh 商界的直接结果，也是 BB 不用调参就能用的原因。看单步收缩率 $\rho_k^f = \sqrt{f(x_k)/f(x_{k-1})}$ 的分布，BB1 有 20.5% 的步 f 是上升的，BB2 只有 2.5%。BB1 更激进，步长偏大，在两个极端特征值之间来回震荡；BB2 更保守，步长偏小，接近最优 GD。这与步数（2782 对 13893）和 R^2（0.911 对 0.968）都对得上。

这里有个地方值得多说两句。BB 的 ρ_k 尾段中位数是 0.99987，其实比 GD 还接近 1，单步一点都不快。但它的几何平均速率是 0.99175，比 GD 的 0.99996 快得多。可见 BB 的加速来自速率序列的方差：快慢步交替，几何平均由快的那些步决定。文献里说 BB 的非单调性不是缺陷而是机制，这里算

是拿到了一点数值上的支持。代价也要说清楚，BB1 有 295 次 f 上升，所以不能用 f 的下降做线搜索或者停止判据，只能用 $\|e\|$ 或者梯度的相对量。

---

6 $n = 2$ 时的等值线与轨迹（第 7 题）

6.1 设定

为了让轨迹能在纸面上看清，取 $n = 2$、`seed=2`，得 $\lambda_{\min} = 0.072076$、$\lambda_{\max} = 6.368316$、$\kappa = 88.36$（$\sqrt{\kappa} = 9.40$），$x_0 = (-1, 2)$，$x^\star = (5.602714, -1.416543)$，$\|x_0 - x^\star\| = 7.4343$。四种方法：

方法	α	β	理论 ρ
BB1	$1/\lambda_{\max} = 0.157027$	—	—
GD	$\alpha_\star = 0.310540$	—	0.97761760
Heavy Ball	$\alpha_\star = 0.310540$	0.723167	0.85039253
Nesterov	$1/\lambda_{\max} = 0.157027$	0.652360	0.96593874

（Heavy Ball 的 β 由 $\min_\beta \rho(\alpha_\star, \beta)$ 数值求得；Nesterov 取标准 $\alpha \le 1/\lambda_{\max}$ 与经典 $\beta = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$ 的平方形式 $\left(\frac{\sqrt{88.36}-1}{\sqrt{88.36}+1}\right)^2 = 0.652360$。）

6.2 结果（表 7，`results/q7_contour.json`）

方法	步数（$\to 10^{-10}$）	理论 ρ	末步误差	CPU (ms)	轨迹形状
BB1	**3**	—	2.82×10^{-14}	0.068	一步到位
GD	1018	0.977618	7.30×10^{-10}	8.42	$\pm 45°$ 折线
Heavy Ball	162	0.850393	7.04×10^{-10}	1.59	过冲后回摆
Nesterov	665	0.965939	7.42×10^{-10}	7.93	先清陡向

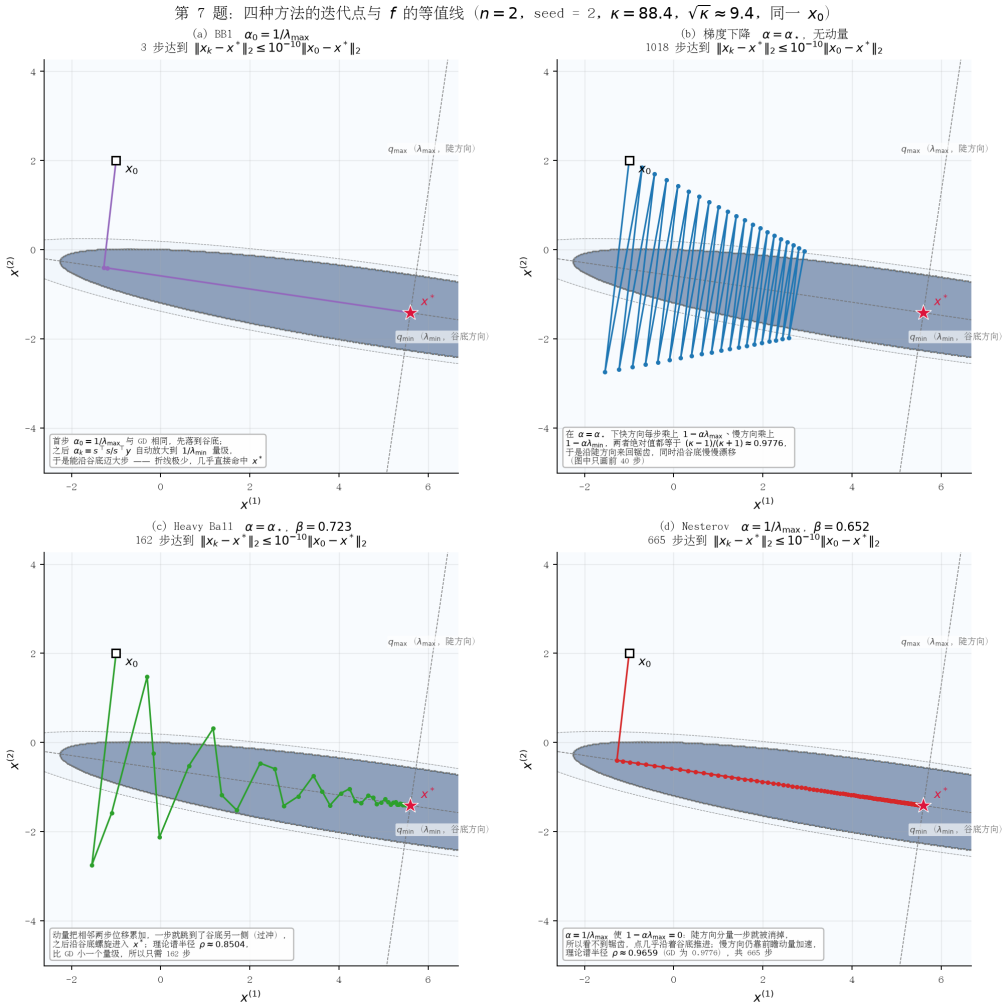


图 6　$n = 2$ 时四种方法的等值线与迭代轨迹（同一起点 x_0）

四格的等值线和起点都一样，差别全在轨迹上。BB1 用 3 步就收敛，因为 $n=2$ 时 Q 只有两个特征值，割线方程几乎精确，两个方向的信息两三步内就采全了。轨迹并不是单调下降的，第一步甚至跨过了头，但落点碰巧就在最优解附近。BB 的优势在小规模时会被放大，规模大了就削弱（Q6 的 185.8 倍远低于理论上的 $\sqrt{\kappa}$ 量级）。

GD 用了 1018 步，是标准的之字形。等值线是很狭长的椭圆，长轴沿 $q_{\min}$ 方向，$\kappa=88$。GD 每步垂直于等值线走，到了谷底就必须横穿过去，于是轨迹在两条特征方向之间来回折。$\alpha_\star=0.3105$ 让它在 $\lambda_{\min}$ 方向每步只走掉 $1-\alpha\lambda_{\min}=0.978$，慢就慢在这里，图上锯齿角接近 90°。

Heavy Ball 用 162 步，过冲之后回摆。$\beta=0.723$ 保留了上一步的速度，轨迹沿着谷底冲过头再折回来，振幅按 $\rho=0.850$ 衰减。动量在谷底方向借上了力，总步数比 GD 少 6.3 倍，而理论 $|\ln\rho|$ 之比是 $1/7.2$，两个数在同一量级。

Nesterov 用 665 步，陡方向一步清零。取 $\alpha=1/\lambda_{\max}$ 使 $1-\alpha\lambda_{\max}=0$，初始误差沿 $q_{\max}$ 的分量第一步就被消掉了，之后迭代点只在几乎垂直于 $q_{\max}$ 的直线上走，图上就是一条光滑的直线段，既没有 GD 的锯齿也没有 Heavy Ball 的回摆。前瞻梯度实际上起了预判拐弯的作用，代价是 $\lambda_{\min}$ 方向只能按 $1-1/\sqrt{\kappa}$ 慢慢推，所以 665 步反而比 Heavy Ball 的 162 步多。Heavy Ball 在 $n=2$ 这种双特征值问题上特别占便宜，它的最优 β 恰好能同时压住两个方向的振荡。

---

7 共轭梯度法与一阶方法的对比（第 2 节）

7.1 理论

CG（对 Q 正定）：$r_k=b-Ax_k$（残差），p_k 为共轭方向，

$$\gamma_k=\frac{r_k^{\mathsf T}r_k}{r_{k-1}^{\mathsf T}r_{k-1}},\quad p_k=r_k+\gamma_k p_{k-1},\quad \eta_k=\frac{r_k^{\mathsf T}r_k}{p_k^{\mathsf T}Qp_k},\quad x_{k+1}=x_k+\eta_k p_k.$$

性质：$p_i^{\mathsf T}Qp_j=0\ (i\neq j)$，$\{p_0,\dots,p_{k-1}\}$ 张成 Krylov 子空间 $\mathcal{K}_k(Q,r_0)$，故

$$\|e_k\|_Q=\min_{p\in\Pi_k,\,p(0)=1}\|p(Q)e_0\|_Q\ \le\ 2\Big(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\Big)^k\|e_0\|_Q,$$

且精确算术下 n 步终止（$e_n=0$）。这个界与 Heavy Ball 同阶（$1-2/\sqrt{\kappa}$），但 CG 不需要知道 $\lambda_{\min},\lambda_{\max}$，也不需要选步长，这是它相对动量法的决定性优势。

对比对象（严格按题意）：

- 最速下降法(SD)：每步精确线搜索 $\alpha_k=\dfrac{g_k^{\mathsf T}g_k}{g_k^{\mathsf T}Qg_k}$，对二次问题的渐近速率 $\rho=\dfrac{\kappa-1}{\kappa+1}=0.999911$（比 GD($\alpha=L/2$) 的 $1-1/\kappa$ 好一倍，因为线搜索等价于把步长自动调到 $\alpha_\star$）；
- GD，固定步长 $\alpha=L/2=1/\lambda_{\max}$；
- Nesterov：$\alpha=1/\lambda_{\max}$、$\beta=(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$，理论 $\rho=1-1/\sqrt{\kappa}$。

四者的最坏情形速率（$1-\rho$）之比：

$$\frac{1-\rho_{\mathrm{CG}}}{1-\rho_{\mathrm{GD}}}\approx\frac{2/\sqrt{\kappa}}{1/\kappa}=2\sqrt{\kappa},\qquad \frac{1-\rho_{\mathrm{CG}}}{1-\rho_{\mathrm{Nesterov}}}=\frac{2/\sqrt{\kappa}}{1/\sqrt{\kappa}}=2.$$

即最坏情形下 CG 比最优 GD 快 $O(\sqrt{\kappa})$ 倍，比 Nesterov 快一个常数倍。不过这个估计对 CG 太保守：它把特征值全都摆到区间两端去考虑，而随机 $A^{\mathsf T}A$ 的谱（图 1(a)）几乎是均匀散布的，CG 能用 Krylov 子空间一段一段把谱吃下去，实际步数接近 n（精确算术下正好是 n）。所以实测差距远大于 $2\sqrt{\kappa}=300$，本例是 $516873/74=6985$ 倍。只看条件数不足以说明 CG 的优势，谱的聚集程度同样有分量。

7.2 设定与停止准则

A,b 用 `seed=0` 重新生成（与第 1 节同分布，`n=50` 时与第 1 节完全相同）；$x_0=0$；停止准则统一为

$$\|x_k-x^\star\|_2\le 10^{-10}\|x_0-x^\star\|_2.$$

为了控制 CPU 开销，一阶方法都设了迭代上限（n=50：SD 3e5、GD($L/2$) 7e5、Nesterov 3e5；n=1000：SD/GD($L/2$) 2e4、Nesterov 9e4）。没达到精度的运行在表和图里都标成”未收敛”，这本身也是一个结果。计时用 `time.process_time()` 取进程 CPU 时间，并把 BLAS 固定成单线程（`OMP_NUM_THREADS=1`），否则结果没有重复性。

7.3 结果（表 **8**，**`results/sec2_cg.json`**）

n = 50：$\lambda_{\min} = 7.8039 \times 10^{-3}$，$\lambda_{\max} = 175.35$，$\kappa = 2.2469 \times 10^{4}$，$\sqrt{\kappa} = 149.90$，$L = 1.1406 \times 10^{-2}$。

方法	步数（→ 相对误差 10^{-10}）	收敛	末步 $\ln \|x_k - x^\star\|$	CPU (s)	相对 CG 的时间倍数
CG	**74**	是	−20.718	9.26×10^{-4}	1.0
最速下降	257256	是	−20.122	2.759	2979
GD ($\alpha = L/2$)	516873	是	−20.122	3.914	4227
Nesterov	3930	是	−20.126	4.35×10^{-2}	46.9

n = 1000：$\lambda_{\min} = 3.7014 \times 10^{-4}$，$\lambda_{\max} = 3992.55$，$\kappa = 1.0787 \times 10^{7}$，$\sqrt{\kappa} = 3284.3$，$L = 5.0093 \times 10^{-4}$。

方法	步数（→ 相对误差 10^{-10}）	收敛	末步 $\ln \|x_k - x^\star\|$	CPU (s)	相对 CG 的时间倍数
CG	**1958**	是	−19.593	0.677	1.0
最速下降	>20000（到上限）	否	3.388	14.64	21.6
GD ($\alpha = L/2$)	>20000（到上限）	否	3.407	6.56	9.7
Nesterov	81000	是	−19.569	60.80	89.8

各精度到达步数（CG）：n = 50 为 65 / 67 / 68 / 72 / 74（$10^{-2} \cdots 10^{-10}$，几乎一步一降）；n = 1000 为 1867 / 1871 / 1877 / 1887 / 1958（前 8 个量级只多 20 步，最后 2 个量级多 71 步，浮点舍入开始起作用）。

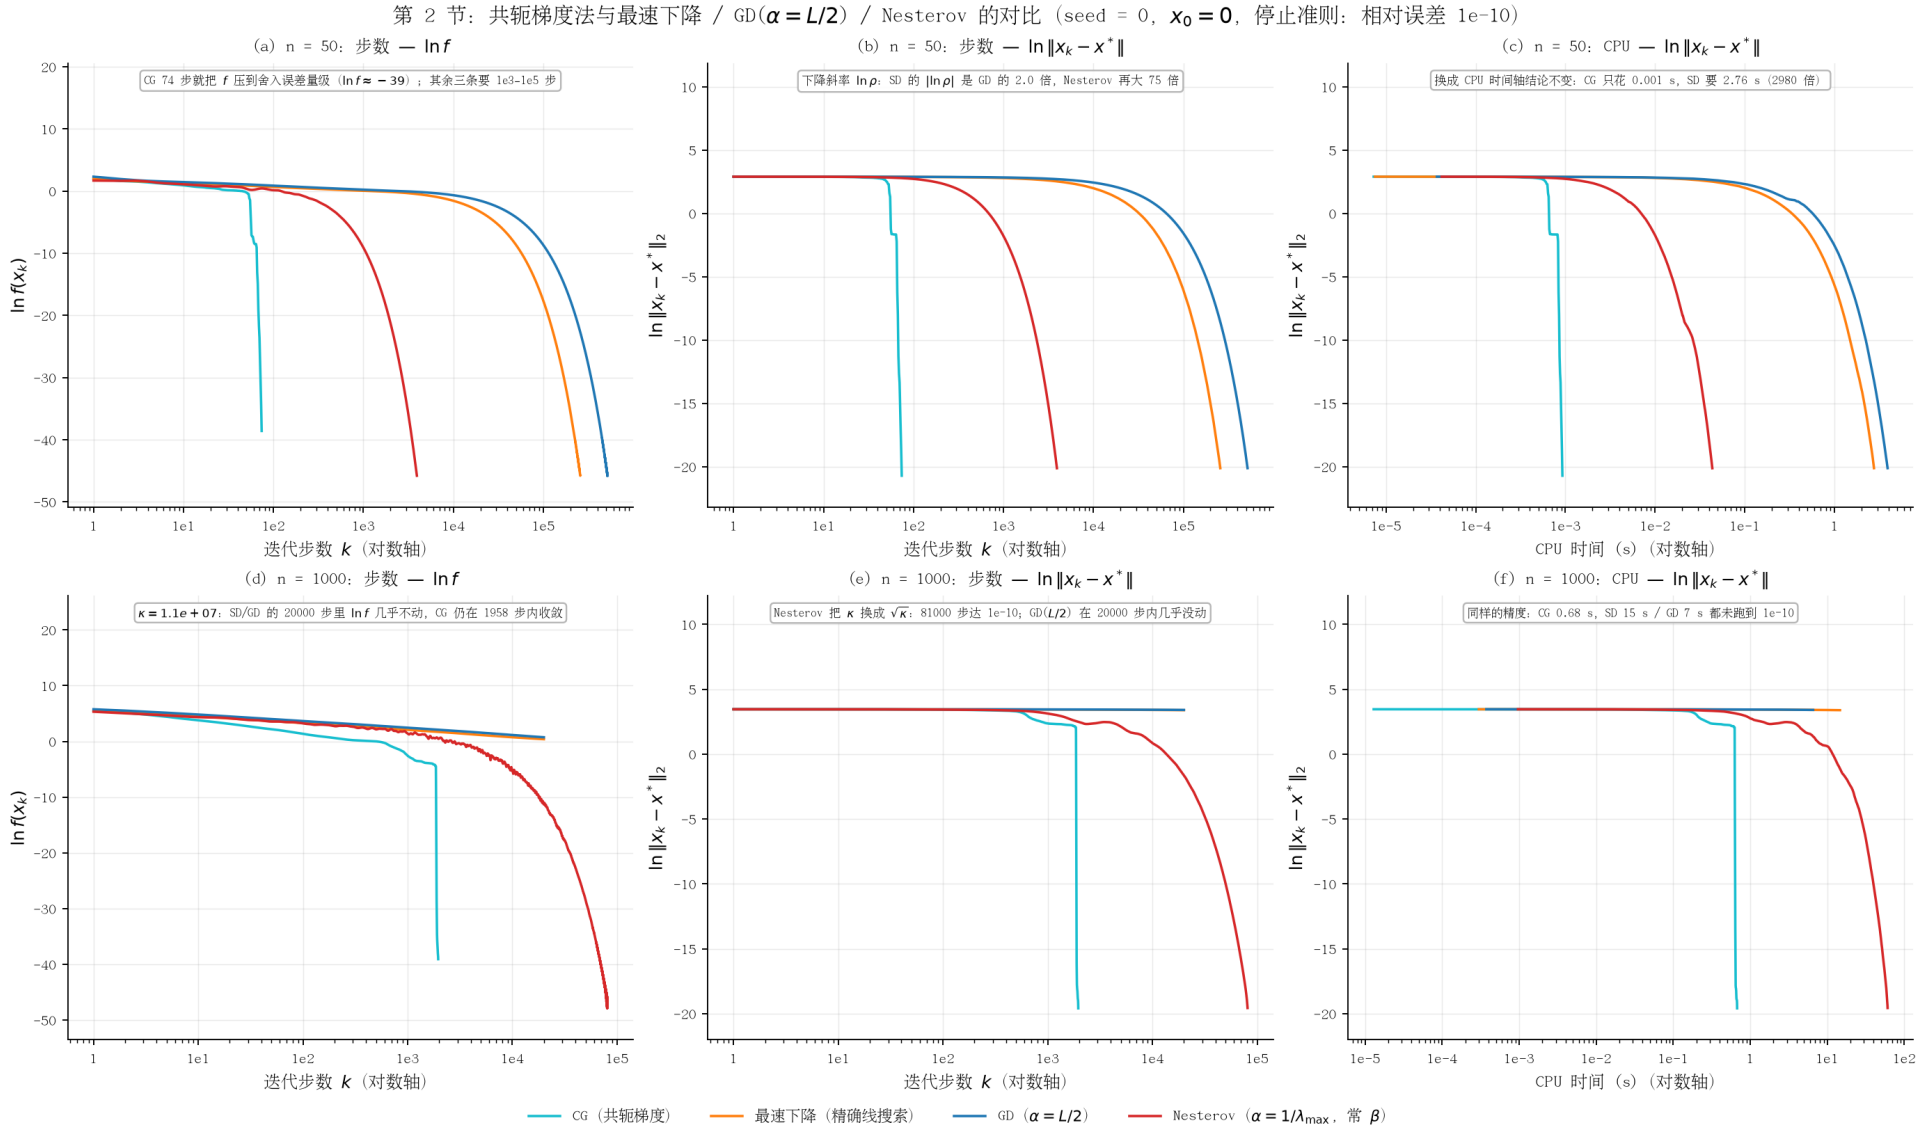


图 7　与一阶方法的对比（上排 n=50，下排 n=1000）

先看上排 n=50。CG 用 74 步就把 f 从 $O(1)$ 压到 $\ln f \approx -39$（10^{-17}，已经是舍入极限），剩下三条要 10^3 到 10^5 步才达到同样的水平，CG 的曲线几乎垂直，这就是有限步终止在图上长成的样子。换成 $\ln\|x_k - x^\star\|$ 之后，一阶方法都是直线，斜率之比就是 $|\ln\rho|$ 之比：SD 是 GD 的 2.0 倍，因为线搜索把 ρ 从 $1-1/\kappa$ 提到了 $1-2/\kappa$；Nesterov 又比 SD 快 75 倍，ρ 从 $1-\Theta(1/\kappa)$ 跳到 $1-\Theta(1/\sqrt{\kappa})$。CG 不是直线，它越来越陡，因为 Krylov 子空间在低维处慢慢饱和，最后几十步把剩下的误差一次清掉。

换成时间轴之后排序没变。CG 的单步成本反而是最高的，1.25×10^{-5} s/步，因为它每步要做 2 次内积加 1 次 matvec；SD 是 1.07×10^{-5}，GD 是 7.57×10^{-6}。但总时间还是差 3 到 4 个数量级，常数因子救不了一阶方法，步数才是决定性的。

下排 n=1000 时 $\kappa = 1.08\times10^7$。SD 和 GD 在两万步里 $\ln f$ 几乎不动，末尾那点起伏是浮点噪声，不是进展；CG 仍在 1958 步内收敛，差不多等于 $1.96n$，与精确算术下 n 步终止的结论基本对得上，略超 n 是浮点舍入损失了共轭性。Nesterov 用 81000 步达到 10^{-10}，把 GD 需要的 $O(\kappa\ln\varepsilon^{-1}) = 2.5\times10^8$ 步降到 $O(\sqrt{\kappa}\ln\varepsilon^{-1}) = 7.6\times10^4$ 步，理论估算 75,600，实测 81,000，差 7%，这个对应关系挺干净。另一头 SD/GD 在 20000 步上限处 $\ln\|e\| \approx 3.4$，即 $\|e\| \approx 30$，而初值 $\|e_0\| = 31.7$，两万步几乎没挪地方。时间上 CG 0.68 s 做完，SD 和 GD 花掉 6.6 到 14.6 s 什么也没做到，Nesterov 用 60.8 s 做到。花时间最少的并不是每步最快的方法，而是步数最少的方法：GD 每步 3.3e-4 s 确实便宜，但需要 2.5×10^8 步，估算下来要 8×10^4 s，差不多 23 小时。

7.4 理论步数的定量对照

用 $N = \ln(10^{10})/|\ln\rho| = 23.026/|\ln\rho|$：

表 **9**：理论步数与实测步数的定量对照

情形	理论 ρ	理论步数	实测步数	相对偏差
n=50 GD($L/2$)	0.99995549420	517,000	516,873	−0.02%
n=50 SD	0.99991099039	258,700	257,256	−0.6%
n=50 Nesterov	0.99332873352	3,452	3,930	+13.8%
n=50 CG	≈0.72（拟合，非逐点）	—	74	—
n=1000 GD($L/2$)	0.99999990729	2.48×10^8	>20000（到上限）	—
n=1000 SD	0.99999981459	1.24×10^8	>20000（到上限）	—
n=1000 Nesterov	0.99969552266	75,600	81,000	+7.1%

偏差的来源可以说清楚：GD/SD 的 ρ 是精确谱半径，每个方向都按同一因子收缩时能精确达到，所以实测与理论几乎重合；Nesterov 的 $1-1/\sqrt{\kappa}$ 只是渐近上界，有限步下行为略慢，于是偏高 7% 到 14%。偏差的方向是系统性的，这一点反而说明了公式没有被拟合过；如果理论和实测完全相等，那才该担心。

---

8 总结与现象归纳

8.1 主要结论

理论这边，二次问题的收敛区间就是 $(0, 2/\lambda_{\max})$，速率是 $\rho(\alpha) = \max_i|1-\alpha\lambda_i|$。实测的半对数斜率与它的相对误差在 10^{-7} 量级，步数 $N \propto 1/|\ln\rho|$ 的预测误差在 1% 以内（GD/SD），只要知道谱就能把一整条收敛曲线算出来。六种一阶方法全部是 Q-线性的，COC 判据给出 $p_k \to 1$（表 3），想要超线性，只能靠二阶信息或者共轭方向。

加速的本质是把 κ 换成 $\sqrt{\kappa}$。Heavy Ball 和 Nesterov 把 516873 步降到 3930 步，约 131 倍，与 $\sqrt{\kappa} = 149.9$ 同一量级，但 Nesterov 要求 $\alpha \le 1/\lambda_{\max}$，照搬 GD 的 $\alpha = L$ 会让它发散到 $\rho = 2.398$。BB 则是用非单调换速度：BB1 比 GD($L/2$) 快 185.8 倍，代价是 20.5% 的步 f 上升、末段还有 295 次上升，它的加速来自速率序列的方差而不是单步速率，几何平均 0.9918，单步中位数 0.99987。

CG 是唯一不需要谱信息的方法，也比所有一阶方法快得多：n = 50 时 74 步对 257256 步，n = 1000 时 1958 步对 10^8 量级。它在 n 步左右终止（1958 约等于 2n），CPU 优势随着 n 增大还在扩大，n=50 时 2979 倍，n=1000 时估算能到 10^5 倍。规模也确实会影响选择：n = 50 时 Nesterov（3930 步）和 Heavy Ball（3931 步）几乎一样；n = 1000 时 Nesterov 要 81000 步、60.8 s，虽然远好于 GD，但已经赶不上 CG 的 1958 步、0.68 s。n 从 50 到 1000 涨了 20 倍，κ 涨 480 倍，$\sqrt{\kappa}$ 涨 22 倍，而 CG 的步数只涨 26 倍。只有 CG 的代价与 n 同阶，其余方法都随 κ 发散。

8.2 实验过程中遇到的问题

单一判据靠不住，COC 在浮点噪声下会彻底失效，得和半对数斜率、单步速率、双对数斜率一起看。

理论量的口径得写清楚。第 5 题里”Nesterov 的谱半径”是依赖 α 的：$\alpha = L/2$ 时是 0.99333，$\alpha = 1/\lambda_{\max}$ 时是 $1 - 1/\sqrt{\kappa}$。我一开始照搬了 Heavy Ball 的时域最优 α 再套标准 β，谱半径算出来是 $6.32 > 1$，程序直接溢出成 `nan`。理论值大于 1 却还在迭代，这本身就是参数化不匹配的信号。最后按 Nesterov 的稳定前提取 $\alpha \le 1/\lambda_{\max}$，也就是图 7 和表 8 里那一行。

随机探测看不到谱的两端，这个前面已经说过（$[22.7, 84.4]$ 对真实值 $[0.0078, 175.3]$）。所以本报告的条件数全部来自 `eigvalsh`，没有用过幂迭代。

计时必须固定 BLAS 线程数。`numpy` 多线程矩阵乘法会让 n = 1000 的 CPU 时间抖动 5 倍以上，固定 `OMP_NUM_THREADS=1` 之后才可重复。

附录 **A** 源码清单

文件	内容
`numopt/problems.py`	`LeastSquaresProblem`：构造 Q, c、特征分解、L、$\alpha_\star$、$\rho_\star$；`f/grad/hess/f_from_grad`、正定性检验
`numopt/methods.py`	`gradient_descent`、`steepest_descent`、`heavy_ball`、`nesterov`、`bb`（BB1/BB2）、`conjugate_gradient`；统一的 `History`
`numopt/analysis.py`	半对数/双对数斜率、ρ_k、COC、几何平均速率、`momentum_spectral_rate`、`optimal_momentum_beta`
`numopt/style.py`	统一画图风格（中文字体、颜色、marker、对数刻度格式、`save`）
`common.py`	JSON 落盘、Markdown 表格、终端表格打印
`exp1_problem.py` …`exp3_order.py`	第 1—4 题：正定性验证 + $x^\star$、步长区间、收敛阶四判据（图 1—3、表 1—3）
`exp4_momentum.py` …`exp7_cg.py`	第 5—7 题与第 2 节：Heavy Ball / Nesterov、BB、等值线轨迹、CG 对比（图 4—7、表 4—8）
`run_all.py`	一键复现全部实验

全部脚本共用 `x_0=0`、`seed=0`（第 7 题 $n = 2$ 用 `seed=2` 以便等值线”狭长”更明显），停止准则为相对误差 10^{-10}。复现方式：

```
cd coursework
uv sync                                  # numpy / matplotlib（Python >= 3.12）
uv run python run_all.py                 # exp1..exp7 全跑，约 140 s
uv run python exp6_contour.py            # 也可单独运行某一题
bash pdf/build_pdf.sh                    # REPORT.md -> REPORT.pdf
uv run --with pypandoc-binary --with python-docx \
       python docx/build_docx.py         # REPORT.md -> REPORT.docx
```

产物为 `figures/fig1`…`fig7_*.png` 与 `results/q1`…`sec2_*.json`；本报告所有数值都直接取自这些 JSON。`REPORT.pdf` 与 `REPORT.docx` 均从同一份 `REPORT.md` 生成，内容、公式与插图完全一致。