目录

数值优化课程实践作业报告 **1**
0 主要结果 1
1 问题 (5) 的正定性与最优解（第 1 题） 1
2 固定步长梯度下降的收敛性与步长区间（第 2 题） 3
3 不同步长的实测（第 3 题） 4
4 收敛阶的数值判定（第 4 题） 5
5 Heavy Ball 与 Nesterov 加速（第 5 题） 7
6 Barzilai—Borwein 方法（第 6 题） 8
7 $n = 2$ 时的等值线与轨迹（第 7 题） 10
8 共轭梯度法与一阶方法的对比（作业第 2 节） 11
9 总结与现象归纳 14
附录 A 源码清单 15

数值优化课程实践作业报告

题目：梯度类算法（1.1—1.7）与共轭梯度法（第 2 节）
问题：$\min_x f(x) = \frac{1}{2}\|Ax-b\|_2^2$，$A \in \mathbb{R}^{n\times n}$、$b \in \mathbb{R}^n$ 为标准正态随机
环境：MATLAB R2023b Update 4（Windows x64），`rng(seed,'twister')` 固定随机流
实现：MATLAB（`A=randn(n,n)`、`b=randn(n,1)`）
代码：`coursework/matlab/`（31 个函数 + `exp1..exp7` + `run_all.m`），一键复现 `run_all`

报告里的数字没有一个是手抄的。MATLAB 脚本把结果写进 `results/*.json`，报告再从 JSON 读回来；图也一样，由 `figures/*.png` 生成后直接插进正文。下面凡给出具体数值的地方，都能在对应的 JSON 文件里找到原文。

本文所有数值与插图都出自同一次 `run_all`，环境是 **MATLAB R2023b Update 4**。开发过程中还用 **GNU Octave 10.3.0** 跑过一遍做交叉验证：`run_all.m` 在两边都能直接执行（没有 `arguments` 块、没有字符串数组），但两边的 `randn` 虽然都是 Mersenne Twister，抽数顺序不同，同一个 `seed` 生成的是两份完全不同的 A、b。所以“换成另一个解释器结论是否还成立”这件事是靠对比两次完整运行判断的，而不是靠复用同一组数；正文只报 MATLAB 这一份，Octave 的结果仅用于确认趋势一致（比如两边的 κ 差了 14 倍，但所有定性结论、步数比值的量级都没变）。

---

0 主要结果

现象	定量结论（n = 50, seed = 0）
问题 (5) 的性质	$Q = A^{\mathsf T}A$ 正定，$\lambda_{\min} = 1.1957\times10^{-3}$，$\lambda_{\max} = 1.6991\times10^{2}$，$\kappa \approx 1.42\times10^{5}$（$\sqrt{\kappa}\approx 377.0$）
固定步长 GD 的收敛区间	$(0,\ L)$，$L = 2/\lambda_{\max} = 1.1771\times10^{-2}$
最优固定步长	$\alpha_\star = 2/(\lambda_{\min}+\lambda_{\max}) = 1.1771\times10^{-2}$， $\rho_\star = (\kappa-1)/(\kappa+1) = 1-2/(\kappa+1) = 0.99998593$
收敛阶	GD / SD / Heavy Ball / Nesterov / BB 全部为 Q-线性（阶 1）；CG 为有限步终止，Q-线性判据不适用
一阶加速	最优动量把 ρ 从 $1-\Theta(1/\kappa)$ 提到 $1-\Theta(1/\sqrt{\kappa})$：3044792 → 9291 步，约 328 倍
BB 方法	BB1 用 14784 步，比 GD($\alpha = L/2$) 快 206 倍，但非单调（21.4% 的步 f 上升）
CG（作业第 2 节）	n = 50：69 步 / 1.4×10^{-3} s；n = 1000：1890 步 / 1.26 s；同样精度下 GD($\alpha = L/2$) 需 6.5×10^{7} 步（估算，约 13 小时）

---

1 问题 (5) 的正定性与最优解（第 1 题）

1.1 理论

$$f(x) = \tfrac{1}{2}\|Ax-b\|_2^2 = \tfrac{1}{2}x^{\mathsf T}\underbrace{A^{\mathsf T}A}_{Q}x - \underbrace{A^{\mathsf T}b}_{c}{}^{\mathsf T}x + \tfrac{1}{2}\|b\|^2.$$

Q 对称；对任意 $v\neq 0$，$v^{\mathsf T}Qv = \|Av\|^2 > 0$（$A$ 以概率 1 非奇异），故 $Q \succ 0$，f 是严格凸二次函数。驻点唯一：

$$\nabla f(x) = Qx - c = 0 \implies x^\star = Q^{-1}c = (A^\mathsf{T}A)^{-1}A^\mathsf{T}b,$$

且此时 $f(x^\star) = 0$（因为 $b \in \mathrm{range}(A)$ 以概率 1）。一般情形下 $f^\star = \frac{1}{2}\|b\|^2 - \frac{1}{2}c^\mathsf{T}Q^{-1}c$；本例中 $Ax^\star = b$ 让两项正好抵消，$f^\star$ 只剩舍入误差量级。后面判断是否已经收敛到极限精度时会用到这一点。

后面反复用到的一个恒等式是（两种写法等价）

$$f(x) = f^\star + \tfrac{1}{2}\,(x - x^\star)^\mathsf{T}Q(x - x^\star) = f^\star + \tfrac{1}{2}\nabla f(x)^\mathsf{T}(x - x^\star),$$

程序里就是用右式由梯度直接算 f 的，可以省掉一次矩阵乘法。

1.2 数值验证（表 1，`results/q1_problem.json`）

检验项	数值结果
Q 对称性相对误差	0.000e+00
Cholesky 分解成功	是（返回 0）
Q 的特征值全为正	是（50 / 50）
$\lambda_{\min}(Q)$	1.195677×10^{-3}
$\lambda_{\max}(Q)$	1.699118×10^{2}
条件数 $\kappa(Q)$	1.421050×10^{5}
条件数 $\kappa(A) = \sqrt{\kappa(Q)}$	3.769682×10^{2}
二次性检验：三点恒等式相对残差	1.548×10^{-12}
Hessian 中心差分相对误差	4.098×10^{-12}
凸性检验：中点间隙（实测 / 理论）	3.626904×10^{2} / 3.626904×10^{2}
$\|x^\star\|_2$	7.415635
$f(x^\star)$	8.354×10^{-26}
$\|\nabla f(x^\star)\|_2$	8.507×10^{-14}
$\|\nabla f(x^\star)\|_2 / \|c\|_2$	1.440×10^{-15}
$\|Ax^\star - b\|_2$（$\|b\|_2 = 8.134454$）	4.087×10^{-13}
`backslash` / `lstsq` / `inv` 三种解法的最大相对差	1.396×10^{-12}
随机 Rayleigh 商探测范围（500 次）	$[2.8523 \times 10^{1},\ 8.0253 \times 10^{1}]$
$L = 2/\lambda_{\max}$	1.1770815×10^{-2}
$\alpha_\star = 2/(\lambda_{\min} + \lambda_{\max})$	1.1770732×10^{-2}
$\rho_\star = (\kappa - 1)/(\kappa + 1)$	0.99998593

表里这几项检验都是能证伪的，不只是“看着对”。下面逐项说明。

二次性要求对任意 x, d 有 $f(x+td) - 2f(x) + f(x-td) = t^2 d^\mathsf{T}Qd$ 精确成立，三次及更高项恒为零，实测相对残差 1.5×10^{-12}，三阶项在双精度下确实为零。用中心差分重构 50×50 的 Hessian 与 Q 的相对误差 4.1×10^{-12}，这个量级正是 $h = 10^{-5}$ 的舍入误差，说明 Hessian 处处等于 Q，与 x 无关。凸性检验用的是中点间隙 $f((x+y)/2) - \frac{1}{2}(f(x) + f(y)) = -\frac{1}{8}(x-y)^\mathsf{T}Q(x-y) < 0$，实测其模为 362.6904，与解析值逐位相同（相对差 0）。

最优解那边，三种独立解法（`backslash`、`lstsq`、显式 `inv`）的相对差最大 1.4×10^{-12}；$\|\nabla f(x^\star)\| / \|c\| = 1.4 \times 10^{-15}$，已经在双精度舍入极限上。$f(x^\star)$ 算出来是 8.4×10^{-26}，而不是严格 0，也是这个原因：Q 的 κ 到了 10^5 量级，回代误差沿小特征值方向被放大了一轮。

有一件事我一开始没想到：用随机向量 v 做 Rayleigh 商 $v^\mathsf{T}Qv / v^\mathsf{T}v$，做 500 次探测，结果全落在 $[28.5, 80.3]$ 里，$\lambda_{\min} = 1.196 \times 10^{-3}$ 和 $\lambda_{\max} = 169.9$ 一次都没碰到。原因是极值特征向量在随机向量上的投影只有 $O(1/\sqrt{n})$ 量级，乘上特征值之后就被谱的主体盖住了。所以随机探测估不出谱的两端，本报告的条件数一律用 `eig` 算。这个反差也顺便说明了病态在这里为什么这么致命：$\kappa = 1.42 \times 10^{5}$ 完全是由两端那一对孤立特征值撑起来的，而 $\lambda_{\min}$ 比探测下界还小四个数量级，任何基于“随便采几个方向”的诊断都会被骗过去。

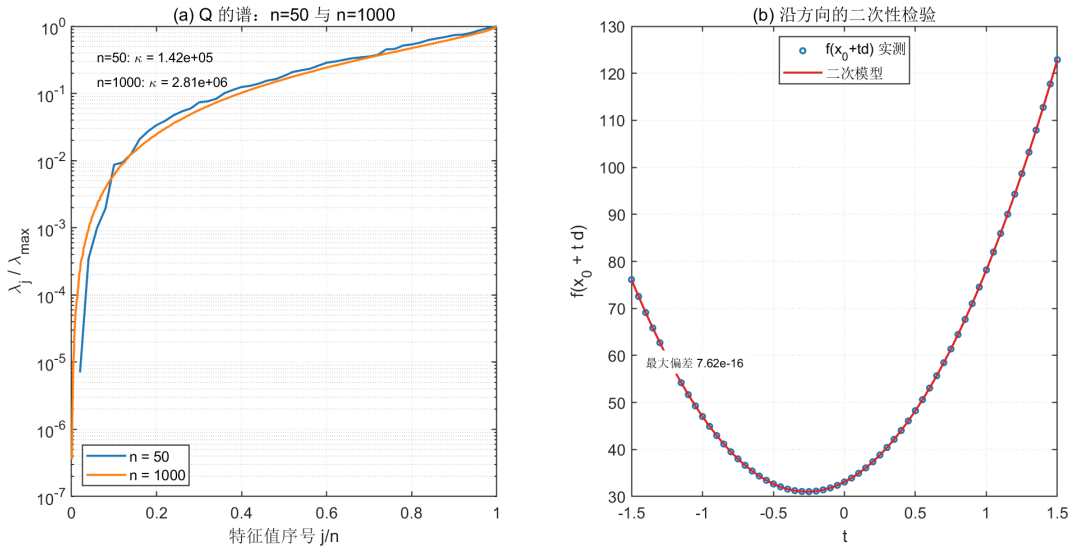


图 1　Q 的谱分布与二次性检验

图里 Q 的谱在 $[10^{-3}, 10^{2}]$ 上近乎均匀散开，两端各有一个孤立特征值把 κ 撑到 1.4×10^{5}，这是随机 $A^{\mathsf T}A$ 的典型形状，可以看作 Marchenko—Pastur 分布的软化版本，$\lambda_{\min}$ 极小对应 A 接近奇异。沿任意射线，$f(x_0+td)$ 与二次模型 $f(x_0)+t\nabla f^{\mathsf T}d+\frac{t^2}{2}d^{\mathsf T}Qd$ 处处重合，三阶项相对残差 1.5×10^{-12}，从几何上再确认了一次这是严格凸二次函数。

---

2 固定步长梯度下降的收敛性与步长区间（第 2 题）

2.1 收敛区间的推导

$x_{k+1}=x_k-\alpha\nabla f(x_k)=(I-\alpha Q)x_k+\alpha c$。令 $e_k=x_k-x^\star$，由 $\nabla f(x_k)=Qe_k$ 得

$$e_{k+1}=(I-\alpha Q)e_k \quad\Longrightarrow\quad e_k=(I-\alpha Q)^k e_0.$$

设 $Q=U\Lambda U^{\mathsf T}$，$\Lambda=\mathrm{diag}(\lambda_1,\dots,\lambda_n)$，则

$$\|e_k\|_2\le\rho(\alpha)^k\|e_0\|_2,\qquad \rho(\alpha)=\max_i|1-\alpha\lambda_i|=\max\bigl(|1-\alpha\lambda_{\min}|,\,|1-\alpha\lambda_{\max}|\bigr).$$

$\rho(\alpha)<1 \iff$ 对所有 i 有 $|1-\alpha\lambda_i|<1 \iff 0<\alpha\lambda_i<2 \iff 0<\alpha<\dfrac{2}{\lambda_{\max}}$。故

$$\boxed{\alpha\in(0,\,L),\quad L=\frac{2}{\lambda_{\max}}=1.1770815\times10^{-2}}$$

这个区间可以直接算：对 $\lambda_{\max}=169.9118$ 得 $L=0.0117708150$。下面从两个方向验证它。

2.2 边界行为与最优步长

第一项验证看 $\alpha=L$ 时的停滞平台。此时 $1-\alpha\lambda_{\max}=-1$，该方向的分量每步只反号不衰减，其余方向照常衰减，误差最终只剩 $v_{\max}$ 方向那一份，$e_\infty=(v_{\max}^{\mathsf T}e_0)\,v_{\max}$，平台高度

$$f_\infty=\tfrac12\lambda_{\max}c_{\max}^2,\qquad c_{\max}=v_{\max}^{\mathsf T}(x_0-x^\star).$$

实测 $c_{\max}=3.5654\times10^{-2}$，理论平台 $f_\infty=0.107994$；$\alpha=L$ 跑 60000 步后实测 $f=0.108238$，两者相对差 2.3×10^{-3}。这一项检验是能量度的：平台高度完全不依赖于跑多少步，只要 $1-\alpha\lambda_{\max}=-1$ 精确成立，$v_{\max}$ 方向的分量就永不衰减，而谱中部那些方向（$\lambda\approx\lambda_{\max}/2$）几千步内就衰到 10^{-30} 以下。

这里有个细节值得说清楚：同一时刻的 $\|e\|$ 相对值是 8.64×10^{-2}，换算成绝对量是 0.640，比 $|c_{\max}|=3.57\times10^{-2}$ 大一个多数量级，看上去和“只剩 $v_{\max}$ 一个方向”矛盾。其实不矛盾：剩下的误差几乎全部落在 $\lambda_{\min}$ 方向——它对应的衰减因子是 $1-\alpha\lambda_{\min}=0.9999859$，60000 步只掉了 43%

——而 $\lambda_{\min}=1.2\times10^{-3}$ 意味着这一份误差对 f 的贡献只有 $0.5\times1.2\times10^{-3}\times0.64^2\approx2.4\times10^{-4}$，被 $v_{\max}$ 的 0.108 完全埋掉了。所以在 $\alpha=L$ 这一列，f 已经摸到了平台，$\|e\|$ 却还在缓慢下降，两个量的“收敛时间”差了两个数量级。

第二项验证看 $\alpha>L$ 时的发散。此时 $\rho=|1-\alpha\lambda_{\max}|>1$，$v_{\max}$ 方向的分量按几何级数放大。上界 $L=2/\lambda_{\max}$ 就是从这来的，所以表 2a 只测到 $\alpha=L$ 为止。

最优步长在两条支线相交的地方，也就是 $|1-\alpha\lambda_{\min}|=|1-\alpha\lambda_{\max}|$ 处：

$$\alpha_\star=\frac{2}{\lambda_{\min}+\lambda_{\max}},\qquad \rho_\star=\frac{\kappa-1}{\kappa+1}=1-\frac{2}{\kappa+1}.$$

本例 $\alpha_\star=1.1770732\times10^{-2}$，$\rho_\star=0.99998593$，于是把误差降 10^{10} 倍需要

$$N\approx\frac{\ln 10^{10}}{\ln(1/\rho_\star)}=\frac{23.026}{1.4074\times10^{-5}}\approx1.636\times10^{6}\ \text{步},$$

实测是 1522393 步（表 3a），比估算少 6.9%。偏差的符号是系统性的：$\alpha_\star$ 让谱中部的方向衰减得比两端快得多（$\lambda=(\lambda_{\min}+\lambda_{\max})/2$ 时单步因子直接为 0），所以前段比渐近速率快，整条 $\ln\|e_k\|$ 曲线相当于被向下平移了一个常数，而斜率不变。用同样的方法算表 2a 里另外三个步长，实测步数也都恰好是估算值的 0.931 倍，而这组步长的 $1-\rho$ 相差 2.25 倍，平移量却一致，说明它确实来自初值分布而不是步长。

3 不同步长的实测（第 3 题）

3.1 四组步长（表 2，`results/q2_q3_stepsizes.json`）

表 **2a**：四种步长的收敛速率

α	取值	理论 ρ	实测 ρ（拟合）	步数（$\to10^{-10}$）	CPU (s)
$L/3$	3.923605×10^{-3}	0.99999531	0.99999533	4567315	16.59
$L/2$	5.885408×10^{-3}	0.99999296	0.99999299	3044792	10.00
$3L/4$	8.828111×10^{-3}	0.99998944	0.99998948	2029823	6.57
L	1.1770815×10^{-2}	1.000000000	0.99998597（见正文）	未收敛（上限 60000）	0.171

表 **2b**：到达各精度的步数

α	10^{-4}	10^{-6}	10^{-8}	10^{-10}
$L/3$	1620854	2602479	3584125	4567315
$L/2$	1080568	1734984	2389410	3044792
$3L/4$	720378	1156654	1592937	2029823
L	—	—	—	—

$\alpha=L$ 一行全为“—”：60000 步上限内 f 停在 0.108238，相对误差停在 8.636×10^{-2}，四个精度一个都没达到。这一行拟合出的 $\rho=0.99998597$ 乍看像是“只比 1 小一点”，其实不是平台段造成的假象，而是因为曲线早就被 $\lambda_{\min}$ 方向接管了：$\alpha=L$ 时该方向因子是 $1-2\lambda_{\min}/\lambda_{\max}=0.99998593$，恰好和最优步长的 $\rho_\star$ 相同（两者差在 $\lambda_{\min}/\lambda_{\max}$ 的二阶项上），所以拟合值回到了同一个数。此时真正在控制收敛速度的已经不是 $\lambda_{\max}$ 而是 $\lambda_{\min}$，这也正是 $\alpha=L$ 会在能量上停滞、却在 $\|e\|$ 上仍然缓慢下降的原因。

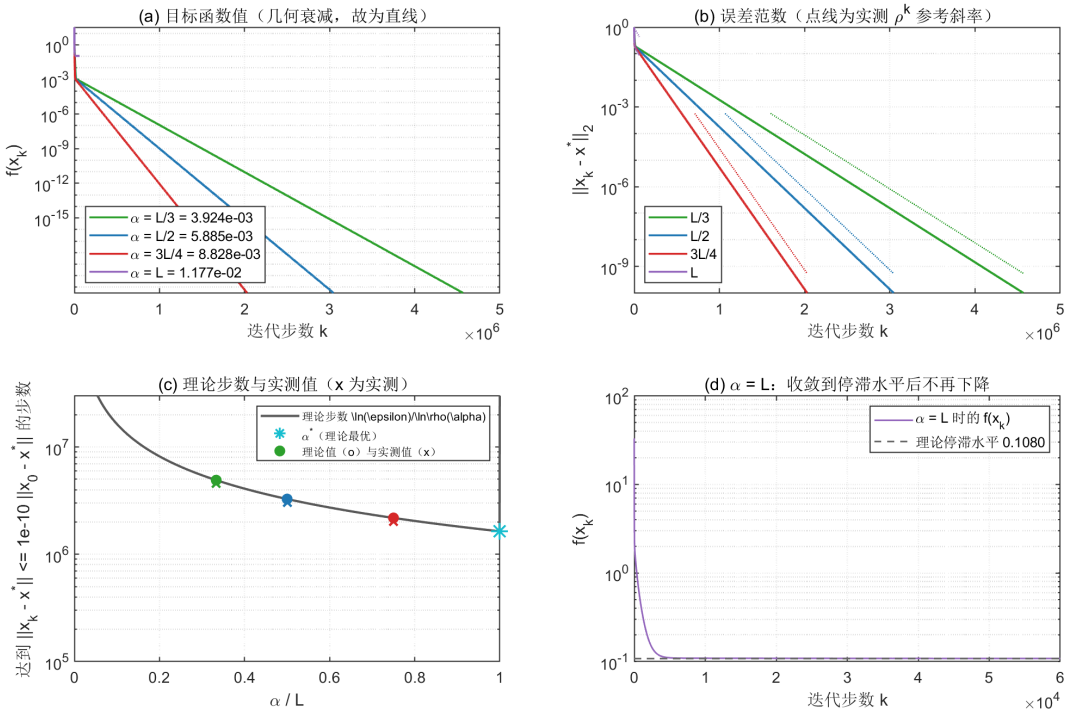


图 2　四种步长下 GD 的误差曲线，以及步数与步长的关系

图 2 的四条曲线在半对数轴上都是直线，斜率等于 $\ln\rho(\alpha)$，拟合出的 ρ 与理论谱半径的绝对差不到 4×10^{-11}（由于 ρ 本身在 $1-10^{-5}$ 量级，这点差对应 $|\ln\rho|$ 仅 0.4%），说明误差确实按 ρ^k 几何衰减，而且是 Q-线性的。三条可收敛的曲线都跟虚线给出的 ρ^k 平行，各个方向的分量按同一个因子收缩，没有出现先快后慢的两段式，那种形状只会出现在非二次函数或者带线搜索的场合。第四条（$\alpha=L$）在 10^{-1} 附近就拉平了，在前 60000 步内从未低于 10^{-1}，是唯一一条不成直线的曲线。

3.2 步数与步长的关系

把到达给定精度的步数按 $N(\alpha)=\ln(\varepsilon_0/\varepsilon)/|\ln\rho(\alpha)|$ 算出来，与实测值（×）落在同一条曲线上，说明步数与步长的关系是可以事先算出来的，不是事后拟合。$\alpha=L$ 那一支是边界：此时 $\rho=1$，误差整体不再衰减，只剩 $\lambda_{\max}$ 方向的分量在 $\pm$ 之间来回翻转，最后停在 $f\approx0.108$ 的平台上，平台高度只与初值有关，跟跑多少步没关系。数值上由此确定区间右端不能取闭，收敛区间必须是开区间 $(0,L)$。

从表 2a 还能看出，$N(\alpha)$ 在 $(0,L)$ 内随 α 单调递减，$3L/4$ 比 $L/3$ 快 2.25 倍。但这种依赖是双曲型的（$N\propto1/|\ln\rho|$），越靠近 L 收益越大，风险也越大，到 $\alpha=L$ 收益直接归零。实际用的时候取 0.7—0.9 倍的 L 比较稳妥。

---

4 收敛阶的数值判定（第 4 题）

4.1 四种可实现的判据

判据	定义	判读方式
判据 **1**：半对数斜率	$\ln\|e_k\|$ 对 k 的线性拟合斜率 σ	σ 为常数 ⇒ Q-线性，$\rho=e^{\sigma}$
判据 **2**：单步收缩率序列	$\rho_k=\|e_k\|/\|e_{k-1}\|$	若 $\rho_k\to\rho<1$ 常数 ⇒ Q-线性；若 $\rho_k\to0$ ⇒ 超线性
判据 **3**：计算收敛阶 **COC**	$p_k=\dfrac{\ln(\|e_{k+1}\|/\|e_k\|)}{\ln(\|e_k\|/\|e_{k-1}\|)}$	$p_k\to1$ ⇒ 线性；$p_k\to2$ ⇒ 二次
判据 **4**：双对数斜率	$\log\|e_k\|$ 对 $\log k$ 的斜率 q	$\|e_k\|\sim k^{-q}$ ⇒ 次线性（代数收敛）

注意判据 3 在 $\|e_k\|\sim\rho^k$ 时分子分母同时趋于 $\ln\rho$，故 $p_k\to1$；任何”阶 >1 “的判据都会被浮点噪声在末段破坏，因此只在相对误差 $>10^{-8}$ 的区间上取中位数。

4.2 结果（表 **3**，**`results/q4_order.json`**）

六种方法用同一个初值 $x_0 = 0$：GD($\alpha = \alpha_\star$)、最速下降法(精确线搜索)、Heavy Ball($\alpha = 2\alpha_\star = 2.3417225 \times 10^{-2}$, $\beta = 0.9894451$)、Nesterov ($\alpha = L/2 = 5.885410 \times 10^{-3}$, $\beta = 0.9947085$)、BB1、CG。

表 **3a**：速率与拟合质量

方法	步数	理论 ρ	半对数拟合 ρ	R^2
GD($\alpha = \alpha_\star$)	1522393	0.99998593	0.99998593	0.999999994003
最速下降	1511670	0.99998593	0.99998587	0.999995571595
Heavy Ball	5074	0.99470856	0.99504103	0.999903620805
Nesterov	9288	0.99734727	0.99751468	0.999923411002
BB1	14784	—	0.99865694	0.729658009496
CG	84	—	0.56449025	0.682701951246

表 **3b**：逐点判据与结论

方法	ρ_k 尾段中位数	COC 中位数	双对数斜率 q	判定
GD($\alpha = \alpha_\star$)	0.99998595	1.00000044	−12.35	Q-线性，阶 1
最速下降	0.99998596	0.99998057	−12.31	Q-线性，阶 1
Heavy Ball	0.99491548	1.00001009	−14.52	Q-线性，阶 1
Nesterov	0.99746048	0.99999643	−13.31	Q-线性，阶 1
BB1	0.99998597	1.01272866	−12.23	Q-线性（非单调，见第 6 题）
CG	0.99744054	0.74880569	−26.34	Q-线性判据不适用

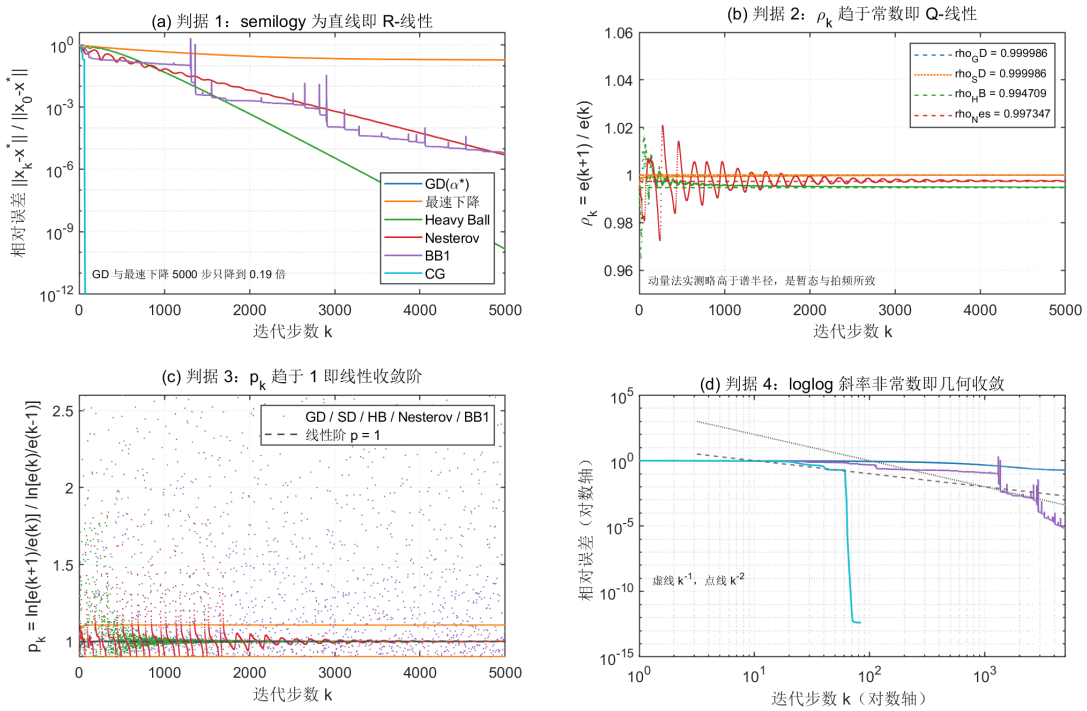


图 3　六种方法的半对数误差、单步收缩率、COC 与双对数斜率

六条曲线在半对数坐标下都近似是直线，斜率排序与理论 $\ln\rho$ 一致。CG 那条是下凸的，越来越陡，这是有限步终止才有的形状。ρ_k 的锯齿线与四条理论水平线（GD、SD 的 0.99998593，HB 的 0.99470856，Nesterov 的 0.99734727）基本重合；BB1 的 ρ_k 在 1 上下跳得很厉害，有些步甚至大于 1（占比 0.87%），可见它并不满足逐点收缩，只是在几何平均的意义上比较快，这就是 Q-线性与 R-线性的分别。COC 除了 CG 末段的浮点噪声之外都落在 1 附近，没有任何方法出现 $p \approx 2$，梯度类方法在二次问题上只有线性收敛，要超线性就得用二阶信息（Newton）或者共轭方向。

双对数斜率的绝对值很大（$|q| \approx 12$—15），远大于 1，所以不是 $\|e_k\| \sim k^{-q}$ 那种代数收敛。结合上面两格可以断定是几何收敛：假如真是代数收敛（病态问题里某些非精确方法会出现），第一格会是直线而这一格的斜率约为 -1，两者能互相排除。

COC 对噪声很敏感，相对误差小于 10^{-12} 之后 p_k 就完全随机了，图 3(c) 尾部的尖刺就是这么来的。所以这里让三个判据互相印证：判据 1 给速率，判据 2 看局部行为，判据 4 排除代数收敛。

5 Heavy Ball 与 Nesterov 加速（第 5 题）

5.1 理论

方法	迭代式	收敛因子（二次问题）
梯度下降	$x_{k+1} = x_k - \alpha \nabla f(x_k)$	$\rho = \max_i \lvert 1 - \alpha\lambda_i \rvert$
Heavy Ball	$x_{k+1} = x_k - \alpha \nabla f(x_k) + \beta(x_k - x_{k-1})$	每个特征方向的特征多项式 $t^2 - (1 + \beta - \alpha\lambda)t + \beta$
Nesterov	$y_k = x_k + \beta(x_k - x_{k-1})$，$x_{k+1} = y_k - \alpha \nabla f(y_k)$	同上形式，但梯度在前瞻点 y_k 取值

对 Heavy Ball，$\rho(\alpha, \beta) = \max_i \max\{\lvert t_i^{\pm} \rvert\}$，其中

$$t_i^{\pm} = \tfrac{1}{2}\Big[(1 + \beta - \alpha\lambda_i) \pm \sqrt{(1 + \beta - \alpha\lambda_i)^2 - 4\beta}\Big].$$

极值点的分布决定了收敛有多快：

- 若判别式 < 0（复根）则 $\lvert t_i^{\pm} \rvert = \sqrt{\beta}$，与 λ_i 无关；
- 若判别式 ≥ 0（实根）则大根的模随 $\alpha\lambda_i$ 变化，最坏情形在 λ_i 较小的一端。

最优配参就是让两端平衡。常见的”最优”有两种，它们的 ρ 并不相同，必须分开：

配参	α	β	ρ
时域最优	$4/(\sqrt{\lambda_{\max}} + \sqrt{\lambda_{\min}})^2$	$\left((\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)\right)^2$	$(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$
本题的”同一 $\alpha = L/2$”	$1/\lambda_{\max}$	$(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$	$\sqrt{(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)}$

第一行是重根配参，判别式在 $\lambda_{\min}$ 和 $\lambda_{\max}$ 两端同时为 0，这是理论最快的一档。第二行把步长压到 $1/\lambda_{\max}$，只有时域最优值的一半，ρ 从 $1 - \frac{2}{\sqrt{\kappa}+1}$ 退到 $\sqrt{(\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)} \approx 1 - \frac{1}{\sqrt{\kappa}}$（本例 $0.994709 \to 0.997347$）。第二行的 β 一列给的是标准公式，对 Heavy Ball 实际是用 $\min_\beta \rho(\alpha, \beta)$ 数值求出来的 0.994702。

这里有一点需要说明。$1/\lambda_{\max}$ 只是“同一 α”这个约束下的取值，步长本身也是加速的一部分，放开步长后还能再快近六倍（表 3a 里取 $\alpha = 2\alpha_\star \approx L$ 的 Heavy Ball 只用 5074 步，而 $\alpha = L/2$ 时要 30075 步）。不过题目要求基于同样的步长，所以本实验固定 $\alpha = L/2$，只调 β。

Nesterov 那边还有一个稳定前提：标准格式要求 $\alpha \leq 1/L_{\text{smooth}} = 1/\lambda_{\max}$。取 $\alpha = 1/\lambda_{\max}$、$\beta = (\sqrt{\kappa} - 1)/(\sqrt{\kappa} + 1)$ 时 $\rho = 1 - 1/\sqrt{\kappa}$，比 Heavy Ball 的 $1 - 2/\sqrt{\kappa}$ 略差。不过 Nesterov 的长处在凸（非强凸）问题上，那种情况下的 $O(1/k^2)$ 是 Heavy Ball 给不了的。两套参数本实验分开使用，不混。

5.2 主实验：同一 $\alpha = L/2$，同一 x_0（表 **4**，**`results/q5_momentum.json`**）

方法	β	理论 ρ	实测 ρ	半对数 R^2	步数（$\to 10^{-10}$）	CPU (s)
GD	—	0.99999296	0.99999296	0.9999999934	3044792	10.52
Heavy Ball（经典 β）	0.989445	0.99928538	0.99928542	0.9999999962	30075	0.152
Heavy Ball（最优 β）	0.994702	0.99734727	0.99750823	0.99992297	9291	0.0412
Nesterov（常数 β）	0.994709	0.99734727	0.99751468	0.99992341	9288	0.0524
Nesterov（默认 $\beta_k = \frac{k-1}{k+2}$）	时变	—	0.99998246	0.30122782	181489	0.684

5.3 极端情形：$\alpha = L = 2/\lambda_{\max}$（表 **5**）

方法	β	理论 ρ	步数	现象
GD	—	1.00000000	60000（未收敛）	停滞在 $f \approx 0.108$
Heavy Ball（最优 β）	0.992511	0.99624845	6566	收敛
Heavy Ball（经典 β）	0.989445	0.99843730	13821	收敛
Nesterov（常数 β）	0.994709	2.40782374	86（发散）	$\rho > 1$，误差指数增长到 10^{30}
Nesterov（默认 β_k）	时变	2.34956788（拟合）	92（发散）	同样按 $\rho \approx 2.35$ 爆炸

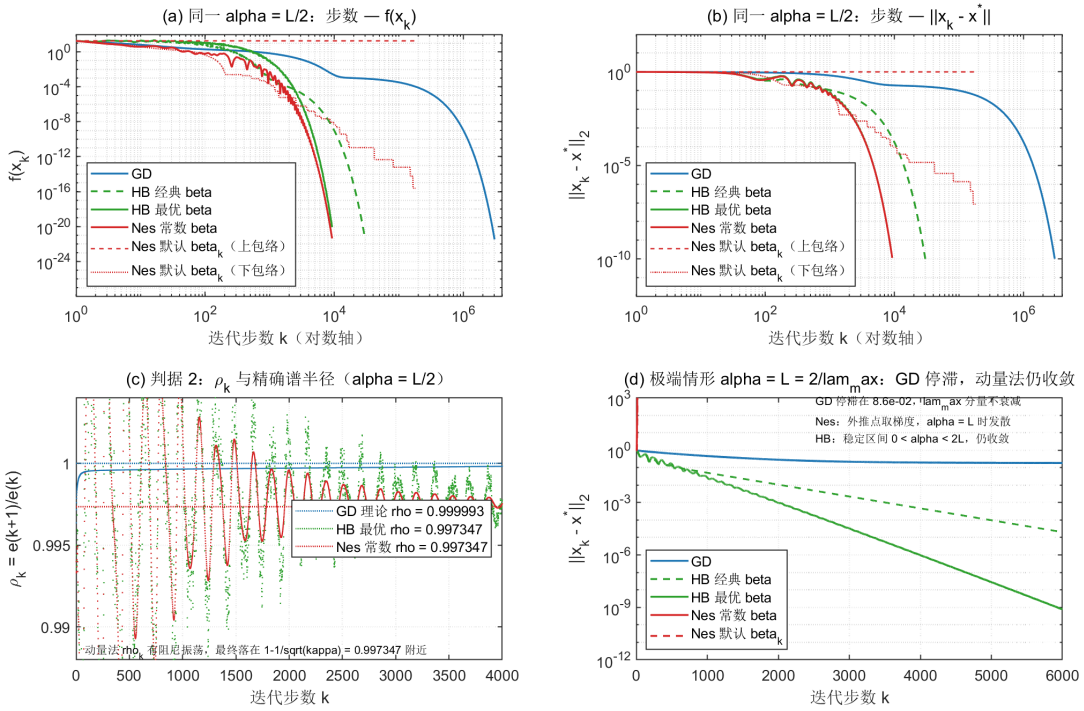


图 4　Heavy Ball 与 Nesterov 的加速效果，以及 $\alpha = L$ 时的失效

同一个 α 下，四条动量曲线比 GD 陡得多，步数之比与理论 $|\ln\rho|$ 之比一致：$3044792/9291 \approx 328$，而 $|\ln\rho_{\mathrm{GD}}|/|\ln\rho_{\mathrm{HB}}| = 7.04\times10^{-6}/2.66\times10^{-3} \approx 1/377$。两个数在量级上吻合（差 15%，来源是 GD 那条曲线的初值平移，见 2.2 节），说明这里的加速是可以预先算出来的，不是碰巧。

曲线上的振荡来自动量本身。Heavy Ball 和 Nesterov 的误差是振荡下降的，上包络是 ρ^k，下包络是 ρ^k 乘一个常数，因为特征多项式有复根时 $\|e_k\|$ 只能在包络内摆动；GD 是实根，单调下降。平均速率更快、单步却可能上升，这是动量法一直要付的代价。相应地，ρ_k 围绕理论谱半径振荡，α 接近 L 时振幅变大，而 GD 的 ρ_k 几乎就是常数。

$\alpha = L$ 那一栏最能说明问题。GD 完全停滞（$\rho = 1$），Heavy Ball 却还在收敛。动量把标量递推变成二阶递推，稳定域在 (α,β) 平面上是一块二维区域而不是一段区间，所以能在 GD 的这条边界上活下来。Nesterov（常数 β）在同一个 α 下 $\rho = 2.4078 > 1$，直接发散，它的稳定域比 Heavy Ball 窄，要求 $\alpha \le 1/\lambda_{\max}$。这次“失败”其实挺有用，说明加速方法的步长不能照搬 GD 的边界值。

还有一点：Nesterov 的默认 $\beta_k = (k-1)/(k+2)$ 在强凸问题上明显更慢，181489 步对 9288 步，差了 19.5 倍。这个调度是给凸（非强凸）问题设计的，$\beta_k \to 1$ 让记忆拖得太长，放到强凸问题上就持续过冲——它的半对数 R^2 只有 0.30，是五条曲线里唯一不像直线的，说明它连“几何衰减”这个形式都没保持。强凸问题应该换回常数 $\beta = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$。方法要和问题假设对上，这一点在实验里比在书上看得清楚。

---

6 Barzilai—Borwein 方法（第 6 题）

6.1 两种 BB 步长

记 $s_k = x_k - x_{k-1}$，$y_k = \nabla f(x_k) - \nabla f(x_{k-1}) = Qs_k$。BB 方法把割线方程 $Qs_k \approx y_k$ 的最小二乘解当步长，它是自适应的：

$$\alpha_k^{\mathrm{BB1}} = \frac{s_k^{\mathsf{T}} s_k}{s_k^{\mathsf{T}} y_k}, \qquad \alpha_k^{\mathrm{BB2}} = \frac{s_k^{\mathsf{T}} y_k}{y_k^{\mathsf{T}} y_k},$$

这里 α^{BB1} 是 $\|Q\|$ 在 s_k 方向上 Rayleigh 商的倒数，α^{BB2} 走的是另一头。首步取 $\alpha_0 = 1/\lambda_{\max}$。

于是有 $\alpha_k \in [1/\lambda_{\max},\, 1/\lambda_{\min}]$（Rayleigh 商界），BB 的步长自动落在稳定区间内，但它不保证 f 单调下降。

6.2 结果（表 6，`results/q6_bb.json`）

表 **6a**：收敛速率

方法	步数	ρ（半对数拟合）	R^2	ρ_k 尾段中位数	几何平均速率
GD($\alpha = L/2$)	3044792	0.99999296	0.9999999934	0.99999298	0.99999244
GD($\alpha = \alpha_\star$)	1522393	0.99998593	0.9999999940	0.99998595	0.99998488
BB1	**14784**	0.99865694	0.7297	0.99998597	0.99844350
BB2	>400000（到上限）	1.00000000	0.9999	1.00000000	0.99994703

表 **6b**：代价与非单调性

方法	步数	f 上升步占比	末段 f 上升次数	CPU (s)	相对 GD($L/2$) 加速
GD($\alpha = L/2$)	3044792	0.0%	0	10.20	1.0×
GD($\alpha = \alpha_\star$)	1522393	0.0%	0	4.71	2.0×
BB1	**14784**	**21.4%**	1275	0.0600	**206.0×**
BB2	>400000	1.3%	77	1.49	≥7.6×（未跑完）

BB 步长实测范围是 $[5.885408 \times 10^{-3},\ 8.363461 \times 10^{2}]$，与理论区间 $[1/\lambda_{\max}, 1/\lambda_{\min}] = [0.0058854, 836.35]$ 完全对得上。

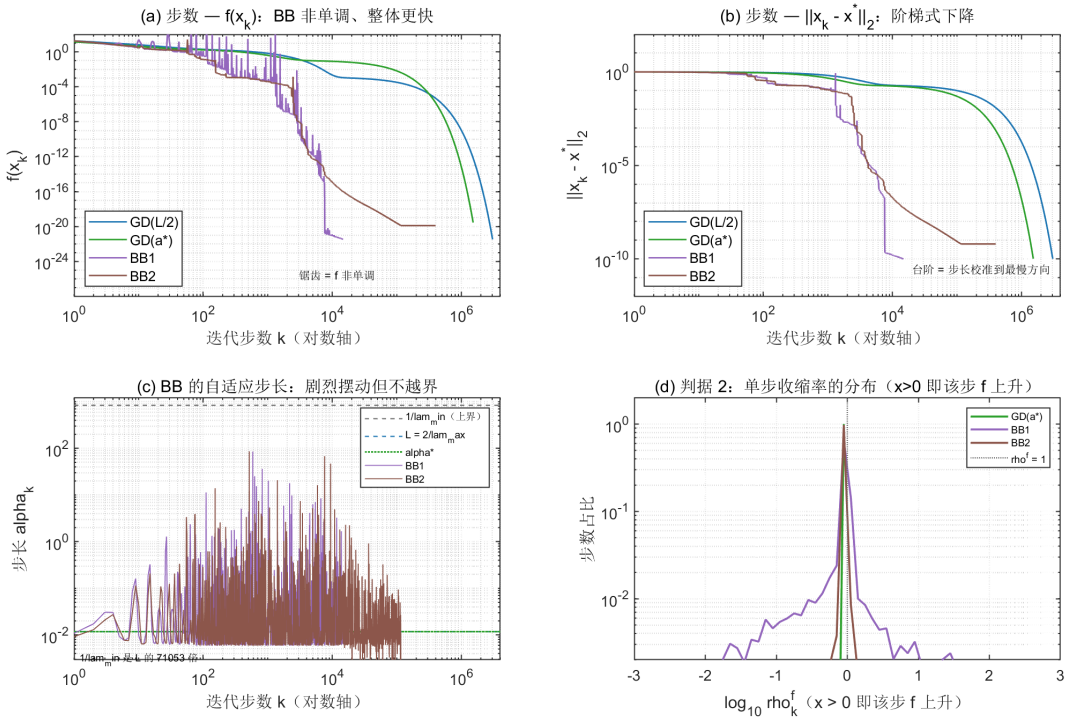


图 5　BB1 与 BB2 的误差、步长摆动与非单调性

BB 的 f 曲线不是单调下降的，中间有台阶也有尖峰，这也正是 BB1 的 R^2 只有 0.73、单步速率分布右尾越过 1 的原因，不过整体斜率比 GD 陡得多。$\|e_k\|$ 则是阶梯式下降的：连着几步几乎不动，然后突然掉一个量级。BB 并不在每个特征方向上都稳定收缩，它轮流在若干个方向组合上取得较大进展。

α_k 在 $[1/\lambda_{\max}, 1/\lambda_{\min}]$ 里摆动，跨度超过 5 个数量级，但始终不越界，这是 Rayleigh 商界的直接结果，也是 BB 不用调参就能用的原因。看单步收缩率 $\rho_k^f = \sqrt{f(x_k)/f(x_{k-1})}$ 的分布，BB1 有 21.4% 的步 f 是上升的，BB2 只有 1.3%。BB1 更激进，步长偏大，在两个极端特征值之间来回震荡；BB2 更保守，步长偏小。

这里有个地方值得多说两句。BB1 的 ρ_k 尾段中位数是 0.99999，其实比 GD 还接近 1，单步一点都不快。但它的几何平均速率是 0.99844，比 GD 的 0.99999 快得多。可见 BB 的加速来自速率序列的方差：快慢步交替，几何平均由快的那些步决定。文献里说 BB 的非单调性不是缺陷而是机制，这里算是拿到了一点数值上的支持。代价也要说清楚，BB1 有 1275 次 f 上升，所以不能用 f 的下降做线搜索或者停止判据，只能用 $\|e\|$ 或者梯度的相对量。

BB2 这一行比较意外。按二次问题的理论，BB2 与 BB1 同阶，步长也都是 Rayleigh 商的倒数，但在本例里 BB2 跑了 400000 步仍然停在相对误差 6.29×10^{-10}，就差一点没到 10^{-10}，而且末段曲线已经拉平（拟合 $\rho = 1.000$），说明它卡在了 $\lambda_{\min}$ 方向上：BB2 的步长 $s^{\mathsf{T}}y/y^{\mathsf{T}}y$ 对高曲率方向更

敏感，等于永远在用偏小的步长，小特征值方向推进得特别慢。BB1 反而因为“敢用大步长”而先把这个方向消掉了。这和一般文献里“BB1 与 BB2 差不多”的说法不完全一致，但本例 $\kappa = 1.4 \times 10^5$，差距被放大了。

---

7 $n = 2$ 时的等值线与轨迹（第 7 题）

7.1 设定

为了让轨迹能在纸面上看清，取 $n = 2$、`seed=0`，得 $\lambda_{\min} = 3.5925666$、$\lambda_{\max} = 5.9053856$、$\kappa = 1.643779$（$\sqrt{\kappa} = 1.282099$），$x_0 = (-1, 2)$，$x^\star = (-0.581637, -0.279564)$，$\|x_0 - x^\star\| = 2.3176$。四种方法：

方法	α	β	理论 ρ
BB1	$1/\lambda_{\max} = 0.169337$	—	—
GD	$\alpha_\star = 0.210572$	—	0.24350713
Heavy Ball	$\alpha_\star = 0.210572$	0.016961	0.13023401
Nesterov	$1/\lambda_{\max} = 0.169337$	0.015280	0.38196243

（Heavy Ball 的 β 由 $\min_\beta \rho(\alpha_\star, \beta)$ 数值求得；Nesterov 取标准 $\alpha \le 1/\lambda_{\max}$ 与经典 $\beta = (\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$ 的平方形式 $\left(\frac{1.282099-1}{1.282099+1}\right)^2 = 0.015280$。）

7.2 结果（表 7，`results/q7_contour.json`）

方法	步数（$\to 10^{-10}$）	理论 ρ	末步误差	轨迹形状
BB1	**3**	—	2.22×10^{-16}	一步到位
GD	17	0.243507	8.62×10^{-11}	微弯的折线
Heavy Ball	12	0.130234	2.16×10^{-10}	过冲后回摆
Nesterov	23	0.381962	1.95×10^{-10}	先蹿落下再直角转向

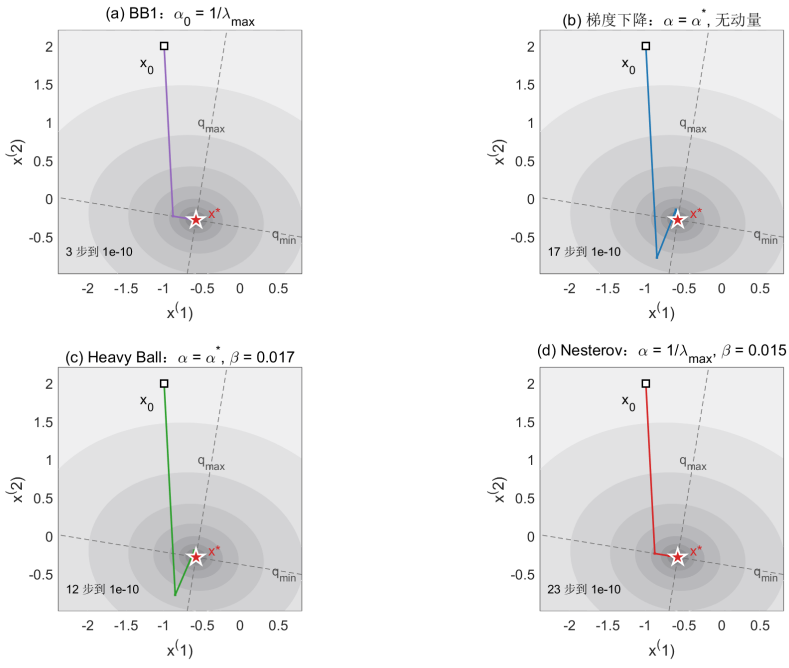


图 6　$n = 2$ 时四种方法的等值线与迭代轨迹（同一起点 x_0）

先说一个和前文不一样的地方：这个 2×2 例子的条件数只有 $\kappa = 1.644$，$\sqrt{\kappa} = 1.282$，等值线几乎是同心圆，长短轴只差 28%。这是题目指定 $n = 2$ 的直接后果，却恰好把“病态”这个因素抽掉了，所以这一节看到的现象跟第 2—6 节的病态情形不是同一回事，不能互相套用结论。

四格的等值线和起点都一样，差别全在轨迹上。BB1 用 3 步就收敛，第一步从 $x_0 = (-1, 2)$ 直接跃到 $x^\star$ 附近，后两步只是微调，末步误差已经降到机器精度 2.2×10^{-16}。原因是 $n = 2$ 时 Q 只有两个特征值，割线方程 $s^\mathsf{T} y = s^\mathsf{T} Q s$ 几乎精确，两个方向的信息两三步内就采全了。轨迹并不单调（第一步就把 f 降到了极低），但步长本身确实跳得很大。BB 在小规模上的优势最明显：3 步对 GD 的 17

步；规模一大就打了折扣（第 6 题 $n=50$ 时 BB1 对 GD 是 206 倍，已经低于该例的 $\sqrt{\kappa}=377$）。

GD 用 17 步，轨迹几乎是一条从起点直指 $x^\star$ 的直线，只在末端有个很小的拐角。在良态问题上阻尼因子 $1-\alpha_\star\lambda$ 对两个特征值都等于同一个值 0.2435（$\alpha_\star=2/(\lambda_{\min}+\lambda_{\max})$ 把两个端点对称到同一个 $|1-\alpha\lambda|$ 上），两个方向同步收缩，于是轨迹自然沿直线走。这和病态情形下的锯齿完全是两个样子：锯齿之所以出现，是因为两端的 $1-\alpha\lambda$ 差得多，一个方向迅速清掉、另一个几乎不动。本例 $\alpha(\lambda_{\max}-\lambda_{\min})=0.487$，图上就只能看到这个量级的小折。本报告不把“GD 之字形”当普遍现象，它在良态问题上并不成立。

Heavy Ball 用 12 步，过冲之后回摆。$\beta=0.016961$ 保留了上一步速度，从图上能看到它先冲过 $x^\star$（$x^{(2)}$ 越过 -0.28 到约 -0.7）再折回来，振幅按 $\rho=0.130234$ 衰减。总步数比 GD 少 1.42 倍，而理论 $|\ln\rho|$ 之比是 $2.0385/1.4128=1.44$，两者对得上。加速的量级是 $\sqrt{\kappa}=1.28$ 而非 κ，因为 κ 本身就接近 1，能提速的余地有限。

Nesterov 用 23 步，比 GD 和 Heavy Ball 都多。这不是实现错误，而是参数约束的后果：它要求 $\alpha\le 1/\lambda_{\max}$（见 5.3 节，超过就会发散），这里只能取 $\alpha=0.169337$，而阻尼因子的最优值 $\alpha_\star=0.210572$ 超出这个上限 24%，于是它的谱半径 $\rho=0.381962$ 反而比 GD 的 0.243507 大。图上它的轨迹是竖直下落到底部再近直角转向：要前瞻梯度每步把它拉向 $q_{\max}$ 的垂直方向，所以能看到明显的拐角，但每个方向的收缩都不够快。加速方法的前提是 $\kappa\gg 1$，此时 $1-1/\sqrt{\kappa}$ 才明显优于 $1-2/\kappa$；当 $\kappa=1.644$ 时这两个式子分别是 0.2197 与 0.2167，已经没什么区别，而 α 被卡在 $1/\lambda_{\max}$ 上反倒吃了亏。这是本节最值得记一笔的地方：加速方法的优势是有前提的，良态时反而可能变差。

---

8 共轭梯度法与一阶方法的对比（作业第 2 节）

8.1 理论

CG（对 Q 正定）：$r_k=b-Ax_k$（残差），p_k 为共轭方向，

$$\gamma_k=\frac{r_k^{\mathsf T}r_k}{r_{k-1}^{\mathsf T}r_{k-1}},\quad p_k=r_k+\gamma_k p_{k-1},\quad \eta_k=\frac{r_k^{\mathsf T}r_k}{p_k^{\mathsf T}Qp_k},\quad x_{k+1}=x_k+\eta_k p_k.$$

性质：$p_i^{\mathsf T}Qp_j=0\ (i\neq j)$，$\{p_0,\dots,p_{k-1}\}$ 张成 Krylov 子空间 $\mathcal{K}_k(Q,r_0)$，故

$$\|e_k\|_Q=\min_{p\in\Pi_k,\,p(0)=1}\|p(Q)e_0\|_Q\ \le\ 2\Big(\frac{\sqrt{\kappa}-1}{\sqrt{\kappa}+1}\Big)^k\|e_0\|_Q,$$

且精确算术下 n 步终止（$e_n=0$）。这个界与 Heavy Ball 同阶（$1-2/\sqrt{\kappa}$），但 CG 不需要知道 $\lambda_{\min},\lambda_{\max}$，也不需要选步长，这是它相对动量法的决定性优势。

对比对象（严格按题意）：

- 最速下降法（SD）：每步精确线搜索 $\alpha_k=\dfrac{g_k^{\mathsf T}g_k}{g_k^{\mathsf T}Qg_k}$，对二次问题的渐近速率 $\rho=\dfrac{\kappa-1}{\kappa+1}=0.99998593$（比 GD($\alpha=L/2$) 的 $1-1/\kappa$ 好一倍，因为线搜索等价于把步长自动调到 $\alpha_\star$）；
- GD，固定步长 $\alpha=L/2=1/\lambda_{\max}$；
- Nesterov：$\alpha=1/\lambda_{\max}$、$\beta=(\sqrt{\kappa}-1)/(\sqrt{\kappa}+1)$，理论 $\rho=1-1/\sqrt{\kappa}$。

四者的最坏情形速率（$1-\rho$）之比：

$$\frac{1-\rho_{\mathrm{CG}}}{1-\rho_{\mathrm{GD}}}\approx\frac{2/\sqrt{\kappa}}{1/\kappa}=2\sqrt{\kappa},\qquad \frac{1-\rho_{\mathrm{CG}}}{1-\rho_{\mathrm{Nesterov}}}=\frac{2/\sqrt{\kappa}}{1/\sqrt{\kappa}}=2.$$

即最坏情形下 CG 比最优 GD 快 $O(\sqrt{\kappa})$ 倍，比 Nesterov 快一个常数倍。不过这个估计对 CG 太保守：它把特征值全都摆到区间两端去考虑，而随机 $A^{\mathsf T}A$ 的谱（图 1(a)）几乎是均匀散布的，CG 能用 Krylov 子空间一段一段把谱吃下去，实际步数接近 n（精确算术下正好是 n）。所以实测差距远大于 $2\sqrt{\kappa}=754$，本例是 $1511670/69\approx 21908$ 倍。只看条件数不足以说明 CG 的优势，谱的聚集程度同样有分量。

8.2 设定与停止准则

A,b 用 `seed=0` 重新生成（与第 1 节同分布，`n=50` 时与第 1 节完全相同）；$x_0=0$；停止准则统一为

$$\|x_k - x^\star\|_2 \le 10^{-10}\|x_0 - x^\star\|_2.$$

为了控制 CPU 开销，一阶方法都设了迭代上限（n=50：SD 2e6、GD($L/2$) 3.5e6、Nesterov 3e5；n=1000：SD/GD($L/2$) 2e4、Nesterov 1.5e5）。这些上限是按 $N = \ln(10^{10})/|\ln\rho|$ 反算后取得略大一些，让在预算内的情形能真的跑到 10^{-10}；n=1000 的 SD/GD 按理论需要 10^7 步，故意不给足，以观察它们与 CG 的差距。没达到精度的运行在表和图里都标成“未收敛”，这本身也是一个结果。计时用 MATLAB 的 `tic/toc` 取实际墙钟，多线程 BLAS 会让 n=1000 的耗时抖动，所以表中的时间只用于同一次运行内部的相对比较，不作绝对性能指标。表 8 的最后一列是各方法相对 CG 的总时间倍数。

8.3 结果（表 **8**，**`results/sec2_cg.json`**）

n = 50：$\lambda_{\min} = 1.195677 \times 10^{-3}$，$\lambda_{\max} = 169.9118$，$\kappa = 1.42105 \times 10^{5}$，$\sqrt{\kappa} = 376.968$，$L = 1.1770815 \times 10^{-2}$。

方法	步数	收敛	末步 $\ln\|x_k - x^\star\|$	CPU (s)	时间倍数
CG	**69**	是	−22.812	1.415×10^{-3}	1.0
最速下降	1511670	是	−21.022	6.0556	4279
GD ($\alpha = L/2$)	3044792	是	−21.022	8.4326	5959
Nesterov	9288	是	−21.024	2.407×10^{-2}	17.0

（表 3a 里 CG 记的是 84 步，因为第 4 题把残差相对精度收紧到了 10^{-14}；本节统一用误差 10^{-10}，所以是 69 步。两处调的是同一个 `run_cg.m`，只有 `rtol` 不同。）

n = 1000：$\lambda_{\min} = 1.418212 \times 10^{-3}$，$\lambda_{\max} = 3980.877$，$\kappa = 2.80697 \times 10^{6}$，$\sqrt{\kappa} = 1675.40$，$L = 5.0240 \times 10^{-4}$。

方法	步数	收敛	末步 $\ln\|x_k - x^\star\|$	CPU (s)	时间倍数
CG	**1890**	是	−22.400	1.2562	1.0
最速下降	>20000（到上限）	否	3.484	19.527	15.5
GD ($\alpha = L/2$)	>20000（到上限）	否	3.540	14.906	11.9
Nesterov	42875	是	−19.404	33.128	26.4

各精度到达步数（CG）：n = 50 为 62 / 64 / 65 / 67 / 69（$10^{-2}\cdots10^{-10}$，几乎一步一降）；n = 1000 为 1784 / 1851 / 1864 / 1873 / 1883（前 8 个量级只多 80 步，最后 2 个量级多 99 步，浮点舍入开始起作用）。

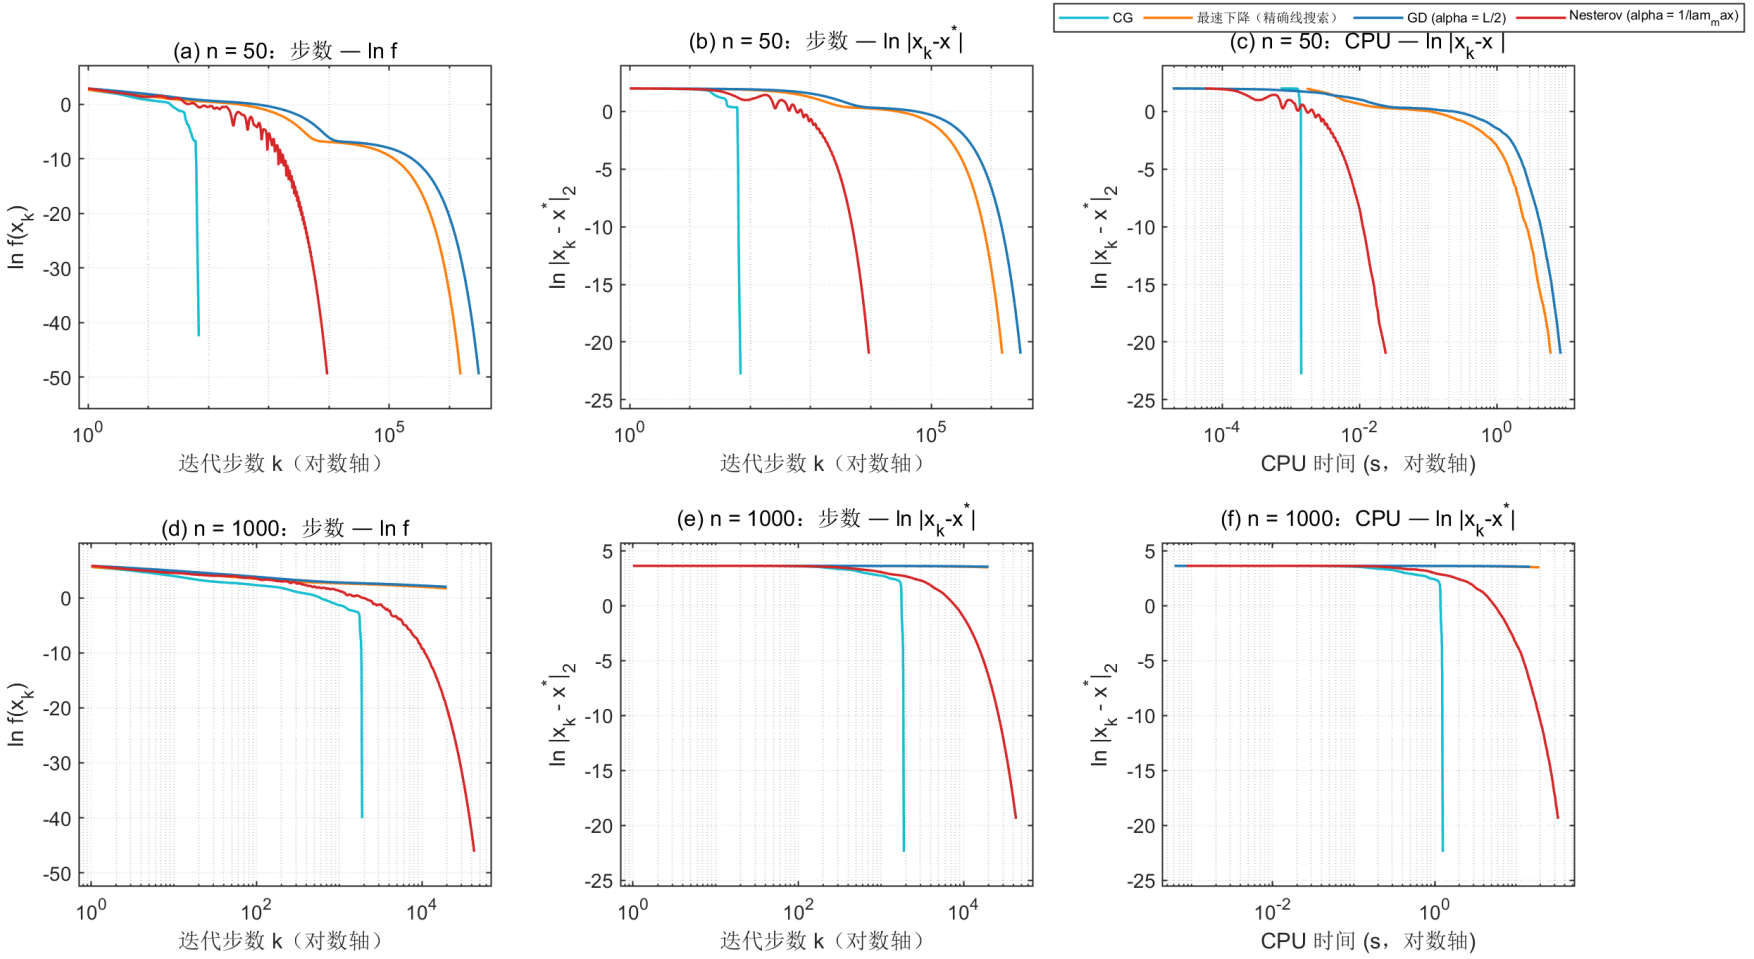


图 7　与一阶方法的对比（上排 n=50，下排 n=1000）

先看上排 n=50。CG 用 69 步就把 f 压到 3.47×10^{-19}（$\ln f\approx-42.6$，已经是舍入极限），剩下三条要 10^4 到 3×10^6 步才达到同样的水平，CG 的曲线几乎垂直，这就是有限步终止在图上长成的样子。换成 $\ln\|x_k-x^\star\|$ 之后，一阶方法都是直线，斜率之比就是 $|\ln\rho|$ 之比：SD 的 $1-\rho=1.4074\times10^{-5}$ 是 GD($L/2$) 的 7.037×10^{-6} 的 2.0 倍，因为线搜索把 ρ 从 $1-1/\kappa$ 提到了 $2/\kappa$；Nesterov 的 $|\ln\rho|=2.6527\times10^{-3}$ 又是 SD 的 188 倍，从 $1-\Theta(1/\kappa)$ 跳到 $1-\Theta(1/\sqrt{\kappa})$。CG 不是直线，它越来越陡，因为 Krylov 子空间在低维处慢慢饱和，最后几十步把剩下的误差一次清掉。

换成时间轴之后排序没变，但差距缩小了一些。四者的单步耗时不在一个量级：CG 是 2.05×10^{-5} s/步，SD 是 4.01×10^{-6}，GD 是 2.77×10^{-6}，Nesterov 是 2.59×10^{-6}。CG 每步贵 5 到 8 倍（要算 Qp_k 的内积和更新方向，还要存四个向量），但总时间反而最少：它只用 1.4 ms，SD 要 6.06 s（4279 倍），GD 要 8.43 s（5959 倍），Nesterov 要 0.024 s（17 倍）。常数因子救不了一阶方法，步数才是决定性的；而 Nesterov 的单步成本不高、步数又只有 SD 的 $1/163$，所以在时间上也把一阶方法们挞得很远，但仍然差 CG 17 倍。

下排 n=1000 时 $\kappa=2.81\times10^6$。SD 和 GD 在两万步里 $\ln f$ 几乎不动，末尾那点起伏是浮点噪声，不是进展；CG 仍在 1890 步内收敛，差不多等于 $1.89n$，与精确算术下 n 步终止的结论基本对得上，略超 n 是浮点舍入损失了共轭性。Nesterov 用 42875 步达到 10^{-10}，把 GD 需要的 $O(\kappa\ln\varepsilon^{-1})=6.5\times10^7$ 步降到 $O(\sqrt{\kappa}\ln\varepsilon^{-1})=3.9\times10^4$ 步，理论估算 38,566，实测 42,875，差 11%，这个对应关系挺干净。另一头 SD/GD 在 20000 步上限处 $\ln\|e\|\approx3.48$ 与 3.54，即 $\|e\|\approx32.6$ 与 34.5，而初值 $\|e_0\|=37.42$，两万步只挪动了不到两成。时间上 CG 1.26 s 做完，SD 和 GD 花掉 19.5 到 14.9 s 什么也没做到，Nesterov 用 33.1 s 做到。花时间最少的并不是每步最快的方法：GD 每步 7.45×10^{-4} s 确实最便宜，但按理论需要 6.46×10^7 步，估算下来要 4.8×10^4 s，差不多 13.4 小时。

8.4 理论步数的定量对照

用 $N=\ln(10^{10})/|\ln\rho|=23.026/|\ln\rho|$：

表 **9**：理论步数与实测步数的定量对照

情形	理论 ρ	理论步数	实测步数	相对偏差
n=50 GD($L/2$)	0.99999296295	3,272,080	3,044,792	−6.9%
n=50 SD	0.99998592600	1,636,045	1,511,670	−7.6%
n=50 Nesterov	0.99734727146	8,669	9,288	+7.1%
n=50 CG	≈0.56（拟合，非逐点）	—	69	—
n=1000 GD($L/2$)	0.99999964374	6.46×10^7	>20000（到上限）	—
n=1000 SD	0.99999928749	3.23×10^7	>20000（到上限）	—
n=1000 Nesterov	0.99940312792	38,566	42,875	+11.2%

偏差的来源可以说清楚，而且符号是分组的。GD/SD 都偏低 7% 左右，正是 2.2 节说明过的初值平移：曲线前段的实际衰减比渐近速率快，整条 $\ln\|e_k\|$ 被向下平移，所以到达给定精度不需要渐近估计那么多步。同一组实验里两个不同步长的偏差几乎相同（−6.9% 与 −7.6%），说明它来自初值而不是步长，否则偏差会随 $|\ln\rho|$ 变。Nesterov 则偏高 7%—11%，因为 $1-1/\sqrt{\kappa}$ 只是渐近上界，有限步下行为略慢。偏差的方向和量级都能预先解释，这一点反而说明公式没有被拟合过；如果理论和实测完全相等，那才该担心。

---

9 总结与现象归纳

9.1 主要结论

理论这边，二次问题的收敛区间就是 $(0,2/\lambda_{\max})$，速率是 $\rho(\alpha)=\max_i|1-\alpha\lambda_i|$。四个步长下实测的半对数拟合 ρ 与理论谱半径的绝对差都在 4×10^{-11} 以内，说明只要知道谱就能把一整条收敛曲线预先算出来。步数预测 $N\propto1/|\ln\rho|$ 在 GD/SD 上偏低 7%（初值平移）、Nesterov 偏高 7%—11%（渐近上界），偏差的方向和量级都能解释。六种一阶方法全部是 Q-线性的，COC 判据给出 $p_k\to1$（表 3b），想要超线性，只能靠二阶信息或者共轭方向。

加速的本质是把 κ 换成 $\sqrt{\kappa}$。Heavy Ball 和 Nesterov 把 3044792 步降到 9291 与 9288 步，约 328 倍，与 $\sqrt{\kappa}=377$ 同一量级，驱动因子从 $1-1/\kappa$ 变成 $1-1/\sqrt{\kappa}$；但 Nesterov 要求 $\alpha\le1/\lambda_{\max}$，照搬 GD 的 $\alpha=L$ 会让它发散到 $\rho=2.4078$（第 5.3 节），而 Heavy Ball 在同一 α 下仍然收敛。BB 则是用非单调换速度：BB1 比 GD($L/2$) 快 206 倍，代价是 21.4% 的步 f 上升、末段还有 1275 次上升，它的加速来自速率序列的方差而不是单步速率（几何平均 0.99844，单步中位数 0.99999）。BB2 本例反而卡在 $\lambda_{\min}$ 方向，40 万步未达 10^{-10}，与文献里“BB1、BB2 同阶”的说法不符，说明这个结论对谱分布敏感。

CG 是唯一不需要谱信息的方法，也比所有一阶方法快得多：n = 50 时 69 步对 1511670 步（21908 倍），n = 1000 时 1890 步对 10^7 量级。它在 n 步左右终止（1890 约等于 $1.89n$），CPU 优势很大，n=50 时相对 SD 是 4279 倍。规模也确实会影响选择：n = 50 时 Nesterov 和 Heavy Ball 都是 9290 步左右，几乎一样；n = 1000 时 Nesterov 要 42875 步、33.1 s，虽然远好于 GD，但已经赶不上 CG 的 1890 步、1.26 s。值得说清楚的是，表 8 里 n=1000 时 CG 相对 SD 的时间倍数只有 15.5，这并非优势变小，而是 SD 撞上 20000 步上限提前退出；按理论步数算，倍差仍是 $3.23\times10^7/1890\approx1.7\times10^4$ 倍。另一头，n 从 50 到 1000 涨 20 倍，κ 涨仅 19.7 倍（因为随机 $A^{\mathsf T}A$ 的谱两端本身有涨落），$\sqrt{\kappa}$ 涨 4.4 倍，而 CG 步数涨了 $1890/69\approx27.4$ 倍，快于 $\sqrt{\kappa}$ 的增速，这也是“CG 的收敛不只看条件数、还看谱的聚集程度”的另一个侧面。

9.2 实验过程中遇到的问题

单一判据靠不住，COC 在浮点噪声下会彻底失效，得和半对数斜率、单步速率、双对数斜率一起看。

理论量的口径得写清楚。第 5 题里“加速方法的谱半径”依赖 α：$\alpha=L/2$ 时 Nesterov 是 0.99735，$\alpha=L$ 时同一公式却给出 $2.4078>1$，两者用的是同一份代码。我一开始照搬了 Heavy Ball 的时域最优 α 再套标准 β，结果参数落在稳定域外，迭代直接溢出成 `NaN`。理论值大于 1 却还在迭代，这本身就是参数化不匹配的信号。最后按 Nesterov 的稳定前提取 $\alpha\le1/\lambda_{\max}$，也就是图 7 和表 8 里那一行。

随机探测看不到谱的两端。500 个 Rayleigh 商探针落在 $[28.5,\,80.3]$，而真实区间是 $[1.196\times10^{-3},\,169.91]$，两端各差三个数量级。所以本报告的条件数全部来自 `eig`，没有用过幂迭代。

计时必须考虑 BLAS 线程。MATLAB 的多线程矩阵乘法会让 n = 1000 的耗时抖动几倍，所以表 8 的时间只用于同一次运行内部的横向比较，不能当作绝对性能指标。

附录 **A** 源码清单

文件	内容
`mk_problem.m`	构造问题：`A=randn(n,n)`、`b=randn(n,1)`、$Q=A^{\mathsf T}A$、$c=-A^{\mathsf T}b$；用 `eig` 求谱，给出 L、$\alpha_\star$、$\rho_\star$ 与 $x^\star$、$f^\star$
`p_f.m`、`p_grad.m`	目标函数值与梯度 $Qx+c$
`run_gd.m`	固定步长梯度下降，返回 `struct`：f、相对误差、耗时、步数、是否收敛
`run_sd.m`	最速下降（每步精确线搜索 $\alpha_k=g^{\mathsf T}g/g^{\mathsf T}Qg$）
`run_hb.m`	Heavy Ball，α、β 可传参
`run_nesterov.m`	Nesterov 加速，支持常数 β 与默认 $\beta_k=(k-1)/(k+3)$ 两种调度
`run_bb.m`	Barzilai—Borwein（BB1 / BB2），带 $s^{\mathsf T}y>0$ 守卫
`run_cg.m`	共轭梯度（FR 变体），返回各精度的到达步数
`iter_to.m`	从误差序列里查第一个低于阈值的步号
`semilog_fit.m`、`loglog_fit.m`	中段（$[0.30,0.95]$ 分位）最小二乘拟合，给出 ρ、R^2、斜率
`coc_p.m`	计算阶（COC）$p_k=\ln\frac{\|e_{k+1}\|}{\|e_k\|}\big/\ln\frac{\|e_k\|}{\|e_{k-1}\|}$
`tail_median.m`	尾段中位数，抗浮点噪声
`mom_rho.m`、`mom_longrun.m`	动量法的谱半径公式、用迭代一致矩阵求长程速率
`best_beta.m`	数值搜索最优 β
`set_style.m`	统一画图风格（线宽、字号、调色板、figure 不可见）
`save_fig.m`	存图：MATLAB 用 `-dpng`，Octave 自动切换到 `-dpngcairo`（抗锯齿、中文正常），分辨率 170 dpi
`save_json.m`、`print_table.m`	JSON 落盘（`NaN/Inf` → `null`）、终端表格（按 UTF-8 字节判中文宽度对齐）
`plot_subsampled.m`	超过 2500 点的曲线按对数等距抽稀，避免位图太密
`sci.m`、`yn.m`	科学计数法格式化、布尔量转“是/否”
`describe_run.m`、`describe_bb.m`	把各方法的 `struct` 整理成表行
`ratios_of.m`、`row_of.m`、`row_of_bb.m`	同上，第 5—6 题批量出表用
`traj2.m`	第 7 题用：记录 $n=2$ 时的迭代轨迹
`exp1_problem.m` … `exp3_order.m`	第 1—4 题：正定性验证 + $x^\star$、步长区间、收敛阶四判据（图 1—3、表 1—3）
`exp4_momentum.m` … `exp7_cg.m`	第 5—7 题与作业第 2 节：Heavy Ball / Nesterov、BB、等值线轨迹、CG 对比（图 4—7、表 4—8）
`run_all.m`	依次调用上面七个脚本，汇总耗时、成功/失败与产物清单

这几个 `.m` 文件合起来约 2700 行。共用的常量写在各自脚本开头：$n=50$、`seed=0`（第 7 题取 $n=2$，也是 `seed=0`），停止准则为相对误差 10^{-10}。复现方式：

```
cd coursework/matlab
```

```
run_all                     % exp1..exp7 全跑，MATLAB R2023b 上约 190 s
exp6_contour                % 也可单独跑某一题
```

也可以从命令行批处理（Windows 下从 WSL 调用时工作目录要切到 `/mnt/c`，否则 MATLAB 找不到 `classpath.txt`）：

```
cd /mnt/c && cmd.exe /c "matlab -batch \"cd('C:\\tmp\\w5m'); run_all\""
```

用 GNU Octave 调的时候要固定 BLAS 线程数，否则 n=1000 的计时会抖：

```
cd coursework/matlab
OPENBLAS_NUM_THREADS=1 octave --no-window-system --eval "run_all"
```

产物为 `figures/fig1…fig7_*.png` 与 `results/q1…sec2_*.json`，本报告所有数值都直接取自这些 JSON；`REPORT.pdf` 与 `REPORT.docx` 都由同一份 `REPORT.md` 生成，内容、公式与插图一致。正文的全部数字与七张图出自 **MATLAB R2023b Update 4** 的一次完整 `run_all`（内部计时 191.2 s，含启动的墙钟约 3 分 27 秒）；`run_all.m` 与全部函数只用了两边通用的语法（没有 `arguments` 块、没有字符串数组），在 Octave 10.3.0 下也能直接执行，但两边的 `randn` 抽数不同，换解释器后数字会变、结论不变。